



Politechnika Warszawska

**Wydział Matematyki
i Nauk Informatycznych**

Metody sztucznej inteligencji 2

**Konspekt projektu 2:
MCTS/UCT w grze
Cooldown Othello 6×6**

Autor:

Wojciech Jasiński

Warszawa, semestr letni 2026

1 Wstęp

Celem projektu jest zaprojektowanie i empiryczna analiza sztucznej inteligencji do gry planszowej dwuosobowej z pełną informacją, opartej o algorytm *Monte Carlo Tree Search* (MCTS) i jego standardowy wariant UCT. Porównujemy wariant bazowy z dwoma ulepszeniami: MC-RAVE oraz progressive bias z heurystyką dziedzinową.

Jako grę wybieramy Othello (historycznie znane jako Reversi) – klasyczną grę o prostych zasadach i bogatej literaturze poświęconej heurystykom pozycyjnym. Pracujemy na zmniejszonej planszy 6×6 oraz wprowadzamy autorską modyfikację zasad – *regulę stygnięcia* (sekcja 3.2), która wprowadza do stanu gry zależność ścieżkową i otwiera nowe pytania badawcze dotyczące skuteczności klasycznych technik MCTS oraz heurystyk dziedzinowych w zmienionych warunkach.

2 Algorytmy

W tej sekcji omawiamy bazowy algorytm MCTS/UCT, dwa rozważane w projekcie ulepszenia (MC-RAVE i progressive bias) oraz rodzinę heurystyk pozycyjnych dla Othello, która dostarcza sygnału dziedzinowego dla progressive bias.

2.1 MCTS i UCT

Monte Carlo Tree Search (MCTS) [1,2] to rodzina algorytmów heurystycznego przeszukiwania drzew gier. Wartość każdego węzła jest estymowana na podstawie statystyk z dużej liczby losowych rozegranych od tego węzła do końca gry. Pojedyncza iteracja składa się z czterech faz:

- *selekcja* – zejście od korzenia po istniejącym drzewie według polityki balansującej eksploatację i eksplorację,
- *ekspansja* – dodanie nowego węzła do drzewa,
- *symulacja* – rozegranie partii od tego węzła do końca, losowo lub według prostej heurystyki,
- *backpropagacja* – uaktualnienie statystyk wszystkich węzłów na ścieżce wynikiem symulacji.

UCT (Upper Confidence Bound applied to Trees) [3] to standardowy wariant MCTS, w którym w fazie selekcji wybierany jest ruch maksymalizujący wartość górnej granicy ufności UCB1 [4]:

$$UCB1(s, a) = \bar{Q}(s, a) + c \sqrt{\frac{\ln N(s)}{N(s, a)}},$$

gdzie $\bar{Q}(s, a)$ to średnia wygrana z ruchu a w stanie s , $N(s)$ – liczba odwiedzeń stanu, $N(s, a)$ – liczba użycia ruchu a , a c – stała eksploracji (typowo $c = \sqrt{2}$). Drugim parametrem algorytmu jest *budżet symulacji* B – liczba iteracji wykonywanych przed wyborem pojedynczego ruchu.

2.2 MC-RAVE

W zwykłym UCT statystyka $\bar{Q}(s, a)$ aktualizowana jest tylko dla par (stan, ruch) faktycznie odwiedzonych w fazie selekcji. **RAVE** (Rapid Action Value Estimation) [5] dokłada do każdego węzła s drugą statystykę – *All-Moves-As-First* (AMAF). Jest to średnia wygranych ze wszystkich symulacji, w których ruch a został zagrany kiedykolwiek po stanie s , niekoniecznie jako pierwszy. AMAF zbiera dane znacznie szybciej niż UCB1, ale jest obciążony: zakłada, że wartość ruchu nie zależy od kontekstu, w którym został zagrany.

W **MC-RAVE** obie statystyki łączy się liniowo:

$$Q_{RAVE}(s, a) = (1 - \beta(s, a)) \bar{Q}(s, a) + \beta(s, a) \bar{Q}_{AMAF}(s, a), \quad \beta(s, a) = \frac{k}{k + N(s, a)}.$$

Mieszanka faworyzuje AMAF, gdy ruch ma niewiele danych z UCB1, i przesuwają się w stronę czystego UCB1, gdy $N(s, a)$ rośnie. Parametr k kontroluje szybkość tego przejścia. Skuteczność RAVE silnie zależy od tego, w jakim stopniu spełnione jest założenie AMAF – dla różnych gier obserwowano bardzo różne efekty [6].

2.3 Progressive bias

Progressive bias [7] to technika integrowania heurystyki dziedzinowej $H(s, a)$ z UCT. Do formuły UCB1 dodawany jest człon $H(s, a)/(N(s, a) + 1)$:

$$\text{UCB1}_{\text{PB}}(s, a) = \overline{Q}(s, a) + c \sqrt{\frac{\ln N(s)}{N(s, a)}} + \frac{H(s, a)}{N(s, a) + 1}.$$

Przy małym $N(s, a)$ heurystyka silnie kieruje wybór ruchu; gdy liczba odwiedzin rośnie, wpływ H maleje, a dominują dane statystyczne z symulacji. Konkretnie heurystyki, których używamy w projekcie jako H , definiujemy w sekcji 4.

3 Gra i modyfikacje

3.1 Othello – klasyczne zasady

Othello to deterministyczna gra dwuosobowa z pełną informacją, rozgrywana na kwadratowej planszy 8×8 dwukolorowymi pionkami (czarny rusza pierwszy). Plansza początkowa zawiera cztery pionki w centrum w układzie krzyżowym. Ruch polega na położeniu pionka swojego koloru w taki sposób, by w co najmniej jednym kierunku domknął on linię pionków przeciwnika ograniczoną własnym pionkiem; wszystkie zamknięte pionki przeciwnika zostają obrócone na własny kolor. Jeżeli gracz nie ma legalnego ruchu, traci kolejkę; gdy żaden z graczy nie może wykonać ruchu, gra się kończy. Wygrywa gracz mający na zakończenie więcej pionków na planszy.

3.2 Modyfikacja: Cooldown Othello 6×6

Wprowadzamy dwie modyfikacje klasycznego Othello:

- **Plansza 6×6** z tym samym centralnym układem startowym czterech pionków co w klasyce. Mniejsza plansza istotnie redukuje przestrzeń stanów (patrz akapit *Złożoność* poniżej), zachowując wszystkie elementy strategii Othello.
- **Reguła stygnięcia (cooldown rule).** Wprowadzamy znacznik „stygnięcia”: pionek z tym znacznikiem chwilowo nie może zostać odwrócony przez przeciwnika ani nie kończy linii domykania. Reguła zdefiniowana formalnie poniżej.

Stan gry. Para (B, C) , gdzie B to konfiguracja planszy (kolor każdego zajętego pola), a C to zbiór pól z aktywnym znacznikiem stygnięcia (pionki postawione lub odwrócone w bezpośrednio poprzedniej turze).

Reguła legalności. Gracz P stawia pionek na pustym polu p . Dla każdego z 8 kierunków d idziemy z p po polach $p + d, p + 2d, \dots$:

- napotkanie pustego pola lub krawędzi planszy – linia w tym kierunku odrzucona,
- napotkanie pionka koloru P – linia akceptowana wtedy i tylko wtedy, gdy w drodze (między p a tym pionkiem) wystąpił co najmniej jeden pionek przeciwnika *bez* znacznika stygnięcia,
- pionki przeciwnika ze znacznikiem stygnięcia są *przezroczyste*: ani nie kończą linii, ani nie czynią jej nielegalną – po prostu nie zostaną odwrócone w tej turze.

Ruch jest legalny, jeżeli istnieje co najmniej jeden kierunek z linią akceptowaną.

Reguła egzekucji. Po wykonaniu legalnego ruchu gracza P :

1. zdejmujemy wszystkie znaczniki stygnięcia (znaczniki postawione w poprzedniej turze właśnie wygasły, $C \leftarrow \emptyset$),
2. stawiamy nowy pionek P na polu p ,
3. w każdej akceptowanej linii odwracamy na kolor P wszystkie pionki przeciwnika *bez* znacznika stygnięcia (ostudzone zostają w swoim kolorze),
4. nowy zbiór C to pole p wraz z wszystkimi polami pionków właśnie odwróconych.

Pasowanie. Jeśli P nie ma legalnego ruchu, pasuje – wykonuje wyłącznie krok 1 powyżej (zdjęcie znaczników), C po pasie jest pusty. Koniec gry: dwa pasy pod rząd (jak w klasyce).

Przypadki graniczne. (a) świeżo postawiony pionek też trafia do C , więc jest chroniony przez 1 turę przeciwnika; (b) w linii mieszanej ostudzone pionki przepuszczamy przezroczyście (geometria linii liczy się klasycznie, filtr stygnięcia działa tylko przy egzekucji); (c) pas zeruje C – znaczniki nie kumulują się.

Uzasadnienie reguły stygnięcia. W klasycznym Othello tzw. *whipsaw* – naprzemienne odwracanie tych samych pionków w kolejnych ruchach – jest częstą taktyką w mid-game. Reguła stygnięcia eliminuje natychmiastowe odwzajemnienie i wprowadza do stanu gry istotną *zależność ścieżkową*: legalność ruchu zależy nie tylko od konfiguracji planszy, lecz także od zbioru pionków odwróconych w poprzedniej turze. Daje to dwa zjawiska centralne dla projektu badawczego:

- algorytm MCTS musi reprezentować stan gry jako parę (**plansza, zbiór ostudzonych pionków**); dwie identyczne pozycje fizyczne nie są semantycznie tożsame, co osłabia działanie standardowych transposition tables [8] i założenie AMAF stojące za algorytmem RAVE;
- klasyczne wagi pozycyjne Buro (sekcja 4.1) – skalibrowane dla swobodnego, w pełni odwracalnego bicia – nie biorą pod uwagę tego, że bicie może chwilowo zabezpieczyć odwracane pionki na jedną kolejkę albo, przeciwnie, zostawić je bez ochrony tuż po wygaśnięciu cooldown.

Złożoność. Klasyczne Othello 8×8 ma długość gry rzędu 60 ruchów i średnie rozgałęzienie rzędu 10, co daje przestrzeń stanów $\sim 10^{28}$ – skalę zbyt dużą dla statystycznie wiarygodnych porównań wielu wariantów MCTS w jednej pracy projektowej. Przejście na 6×6 redukuje tę skalę o kilkanaście rzędów wielkości. Reguła stygnięcia dodatkowo zmniejsza średnie rozgałęzienie, bo część potencjalnych bić jest zablokowana; średnia długość partii pozostaje praktycznie niezmienną, bo warunek końca gry (obaj gracze bez legalnego ruchu) się nie zmienia. Wstępne szacunki dla Cooldown 6×6 to średnia długość ~ 28 ruchów i średnie rozgałęzienie ~ 4 ; wartości zweryfikujemy empirycznie (samogra losowa, 1000 partii) przed głównymi eksperymentami.

4 Heurystyki dziedzinowe

W projekcie korzystamy z dwóch heurystyk dziedzinowych dla Othello: klasycznej heurystyki pozycyjnej Buro oraz jej rozszerzenia świadomego reguły stygnięcia. Każda z nich może być wykorzystana zarówno bezpośrednio (jako jednowarstwowy gracz negamax), jak i pośrednio jako sygnał H w progressive bias (sekcja 2.3).

4.1 Heurystyki pozycyjne dla Othello (Buro)

Najsilniejsze ręcznie projektowane funkcje oceny dla Othello [9, 10] opierają się na dwóch składnikach.

Wagi pozycyjne (Buro 1997). Każdemu polu planszy przypisywana jest waga liczbową odzwierciedlająca strategiczną wartość kontroli tego pola. Rogi otrzymują dużą wagę dodatnią (typowo +100): są pozycjami stabilnymi – raz zajęte, nie mogą zostać odwrócone do końca partii. Pola *X-square* (przylegające skośnie do rogu) mają silnie ujemną wagę (typowo -25), bo ułatwiają przeciwnikowi zdobycie rogu. Pola brzegowe i wewnętrzne otrzymują wagi pośrednie. Wartość pozycji to suma wag pól zajętych przez gracza minus analogiczna suma dla przeciwnika. Tabelę wag dla planszy 6×6 skalujemy z klasycznej 8×8 z zachowaniem struktury jakościowej (rogi cenne, X-square deficytowe, brzeg pośredni).

Mobility. Różnica liczby legalnych ruchów dostępnych dla obu graczy. W mid-game ograniczanie liczby legalnych ruchów przeciwnika jest często silniejszym wskaźnikiem przewagi niż chwilowa różnica liczby pionków na planszy.

Heurystyczny gracz wybiera ruch maksymalizujący ważoną sumę obu składników po jednym ruchu w przód (*negamax* głębokości 1).

4.2 Cooldown-Buro: rozszerzenie świadome reguły stygnięcia

Reguła stygnięcia (sekcja 3.2) zmienia rzeczywistą wartość niektórych ruchów względem klasycznego Othello w sposób, którego nie obejmują same wagi pozycyjne Buro: ruch może odwrócić pionek, który następnie wraca do przeciwnika natychmiast po wygaśnięciu cooldown (bicie *de facto* stratne), albo odwrotnie – pionek jest osłonięty z obu stron własnymi pionkami i staje się stabilny niezależnie od cooldown. Aby uchwycić tę specyfikę, definiujemy **Cooldown-Buro** jako rozszerzenie heurystyki Buro o dodatkowy term oceny:

- *kara*: za każdy odwracany w ruchu pionek, który po wygaśnięciu cooldown będzie „sandwichable” na przeciwny kolor (po jednej kolejce przeciwnik może go z powrotem odwrócić),
- *bonus*: za każdy odwracany pionek, który ma od razu po obu stronach (w tej samej linii) własne pionki – jest więc trwale osłonięty.

Współczynnik wagi tego termu względem klasycznych wag pozycyjnych oznaczamy λ_c i dostrajamy w ramach strojenia hiperparametrów (sekcja 6.3). **Naive-Buro** (sekcja 6.1) używa tylko klasycznej części Buro; **Cooldown-Buro** – pełnej rozszerzonej oceny.

5 Hipotezy badawcze

Każdą hipotezę weryfikujemy równolegle na obu wariantach gry (klasyczny Othello 6×6 i Cooldown Othello 6×6, sekcja 3) z udziałem siedmiu wariantów graczy (Random, Naive-Buro, Cooldown-Buro, UCT, UCT-RAVE, UCT-PB-naive, UCT-PB-cooldown; sekcja 6.1).

H1 (UCT vs heurystyka pozycyjna). UCT bazowy pokonuje Naive-Buro w obu wariantach gry (współczynnik wygranych $\geq 60\%$ na Cooldown 6×6), a jego przewaga jest istotnie większa na Cooldown niż na klasycznym 6×6.

H2 (RAVE). UCT-RAVE pokonuje UCT bazowy w obu wariantach gry, ale przewaga RAVE jest istotnie mniejsza na Cooldown niż na klasyce (różnica we współczynnikach wygranych RAVE–UCT spada o ≥ 3 p.p. przy przejściu z klasyki na Cooldown).

Zależność ścieżkowa stanu osłabia założenie AMAF.

H3 (Cooldown-aware progressive bias). UCT z progressive bias z heurystyką Cooldown-Buro pokonuje UCT bazowy na Cooldown 6×6 (przewaga ≥ 10 p.p.) wyraźniej niż wariant z naiwną heurystyką Buro (UCT-PB-naive), który daje istotnie mniejszą przewagę.

H4 (heurystyka wyspecjalizowana w grze). W bezpośrednim starciu Cooldown-Buro pokonuje Naive-Buro na Cooldown 6×6 (przewaga ≥ 10 p.p.), ale na klasycznym 6×6 obie heurystyki są praktycznie równoważne (różnica < 5 p.p. przy parowanych ziarnach gry).

Hipoteza izoluje wpływ reguły stygnięcia na samą heurystykę dziedziczną od wpływu na MCTS testowanego w H1–H3.

H5 (przewaga drugiego gracza zanika z regułą stygnięcia). Strukturalna przewaga drugiego gracza w klasycznym Othello 6×6 zanika pod regułą stygnięcia: w samogrze najsilniejszego wariantu MCTS (≥ 2000 partii) współczynnik wygranych drugiego gracza wynosi $\geq 55\%$ na klasycznym 6×6 , ale $\leq 50\%$ (nieodróżnialnie od 50% lub niżej) na Cooldown 6×6 .

Whipsaw – natychmiastowe odwracanie świeżo bitych pionków – to taktyka reaktywna, z której silniej korzysta gracz odpowiadający; eliminacja whipsaw odbiera drugiemu graczowi część tej przewagi.

6 Sposób weryfikacji hipotez

6.1 Warianty graczy

Porównujemy siedmiu graczy: prostą kontrolę losową, dwie heurystyki dziedziczne oraz cztery warianty MCTS o rosnącej złożoności.

- **Random** – gra losowo spośród legalnych ruchów. Najprostsza możliwa kontrola; punkt odniesienia, poniżej którego żaden sensowny gracz nie powinien spaść.
- **Naive-Buro** – wybiera ruch po jednym kroku w przód, oceniając pozycję klasyczną heurystyką pozycyjną Buro (sekcja 4.1). Reguły stygnięcia w ogóle nie zna – gra tak samo na obu wariantach gry.
- **Cooldown-Buro** – działa identycznie jak Naive-Buro, ale jego heurystyka jest świadoma reguły stygnięcia (sekcja 4.2): nagradza bicia trwale i karze bicia, które przeciwnik łatwo odwróci po wygaśnięciu cooldown. Pozwala sprawdzić, czy samo dopasowanie heurystyki dziedzicznej do reguły coś daje.
- **UCT** – bazowy MCTS bez żadnych ulepszeń. Pełni rolę punktu odniesienia dla rodziny MCTS: wszystkie kolejne warianty mierzymy jego siłą.
- **UCT-RAVE** – UCT wzbogacony o statystykę MC-RAVE. Pierwsze, dobrze znane z literatury ulepszenie, które w niektórych grach (np. Go) wyraźnie przyspiesza zbieżność oceny ruchów.
- **UCT-PB-naive** – UCT z progressive bias, w którym heurystyka kierująca poszukiwaniem nie wie nic o regule stygnięcia. Wariant kontrolny dla H3: pokazuje, ile zysku daje sam mechanizm progressive bias, niezależnie od jakości heurystyki.
- **UCT-PB-cooldown** – UCT z progressive bias, w którym heurystyka kierująca poszukiwaniem jest świadoma reguły stygnięcia. Główny kandydat na najsilniejszego gracza w turnieju i właściwy obiekt badania w H3 i H5.

6.2 Konfiguracja eksperymentów

Wspólne ustawienia. Budżet $B = 10\,000$ symulacji na ruch dla wariantów MCTS, ≥ 200 partii na każdą porównywaną parę graczy (z zamianą stron), istotność na poziomie $\alpha = 0,05$. Odstępstwa od tych wartości (większe budżety w eksperymencie skalowania, większy sample w H5) opisujemy przy odpowiednich eksperymentach poniżej.

Eksperyment główny H1–H4: turnieje round-robin. Dla każdego z dwóch wariantów gry (klasyk, Cooldown) i ustalonego budżetu $B = 10\,000$ przeprowadzamy round-robin między 7 graczami z sekcji 6.1 (21 par); każda para gra 200 partii z zamianą stron (po 100 dla każdego startującego koloru). Łącznie ~ 4200 partii na wariant gry, ~ 8400 partii ogółem dla głównego turnieju.

Eksperyment H2 (skalowanie efektu RAVE z budżetem). Pary UCT vs UCT-RAVE w obu wariantach gry, $B \in \{1\,000, 5\,000, 10\,000, 30\,000\}$, po 200 partii na punkt. Pozwala sprawdzić, czy efekt z H2 (mniejsza przewaga RAVE na Cooldown) jest stabilny względem budżetu.

Eksperyment H5 (przewaga drugiego gracza). Najsilniejszy wariant z sekcji 6.1 (typowany jako UCT-PB-cooldown) gra przeciwko sobie (≥ 2000 partii) na każdym z dwóch wariantów gry, ze starannym oddzieleniem ziaren generatora losowości obu graczy (różne ziarna dla każdej partii i każdej strony, by uniknąć efektu identycznych rolloutów). Wynik raportowany jako współczynnik wygranych drugiego gracza z 95% przedziałem ufności Wilsona.

Powtarzalność. Każda partia jest deterministycznie odtwarzalna z trójki (**seed gry**, **seed czarnego**, **seed białego**). Wszystkie ziarna i konfiguracje zapisywane są wraz z surowym wynikiem; każdy z głównych pomiarów raportowany z 95% przedziałem ufności.

6.3 Strojenie hiperparametrów

Hiperparametry strojone biblioteką Optuna [11] z samplerem TPE (Tree-structured Parzen Estimator). Funkcją celu jest *średni współczynnik wygranych* przeciw zestawowi kontrolnemu trzech stałych przeciwników – uśrednianie chroni przed konfiguracjami nadmiernie specjalizującymi się w jednym przeciwniku, a self-play odrzucamy, bo równowagowy win rate $\approx 50\%$ daje słaby sygnał dla TPE.

Strojenie idzie kaskadowo (kolejność wierszy w tabeli 1): każdy zestaw kontrolny wykorzystuje wcześniej ustrojone warianty (oznaczone indeksem „_t”); przeciwnicy spoza kaskady są w konfiguracji domyślnej („_def”: $c=\sqrt{2}$, $w_{\text{mob}}=1$, $\lambda_c=1$).

Wspólne ustawienia. Zredukowany budżet $B_{\text{tune}} = 2\,000$ symulacji/ruch ($5\times$ szybszy od docelowego $B = 10\,000$); 30 prób Optuny na algorytm; 60 partii na próbę = 20 vs każdy przeciwnik (po 10 na kolor, sparowane ziarna gry). Heurystyki Buro stroimy tylko na Cooldown 6×6 (jedną konfigurację reużywamy na obu wariantach gry); algorytmy MCTS stroimy osobno na każdym wariancie.

Łączna liczba partii strojących: 2 heurystyki $\times$ 1 wariant + 4 MCTS $\times$ 2 warianty = 10 przebiegów $\times$ 30 prób $\times$ 60 partii = 18 000 partii.

6.4 Eksperyment człowiek–komputer

Przeprowadzamy testy z udziałem co najmniej 5 osób. Każdy uczestnik rozgrywa minimum 6 partii (interfejs CLI lub prosty UI webowy): po dwie przeciwko najsilniejszemu wariantowi MCTS w konfiguracjach (a) klasyczne Othello 6×6 , (b) Cooldown Othello 6×6 z ujawnioną regułą, (c) Cooldown Othello 6×6 z ujawnioną regułą i krótką podpowiedzią taktyki („po cudzym biciu nie próbuj go natychmiast odwrócić”). Kolory dobierane losowo. Zbierane: wynik partii, czas

Strojony	Hiperparametry i ich zakresy	Zestaw kontrolny (3 przeciwników)
Naive-Buro	$w_{\text{mob}} \in [0; 5]$ (skala liniowa)	• Random • UCT_def ($B=500$) • Cooldown-Buro_def
Cooldown-Buro	$\lambda_c \in [0,1; 4]$ (skala liniowa) $w_{\text{mob}} \in [0; 5]$ (skala liniowa)	• Random • Naive-Buro_t • UCT_def ($B=500$)
UCT	$c \in [0,5; 2,5]$ (skala liniowa)	• Random • Naive-Buro_t • Cooldown-Buro_t
UCT-RAVE	$c \in [0,5; 2,5]$ (skala liniowa) $k \in [10; 5\,000]$ (skala logarytmiczna)	• Naive-Buro_t • Cooldown-Buro_t • UCT_t
UCT-PB-naive	$c \in [0,5; 2,5]$ (skala liniowa) $w_H \in [0,1; 10]$ (skala logarytmiczna)	• Naive-Buro_t • UCT_t • UCT-RAVE_t
UCT-PB-cooldown	$c \in [0,5; 2,5]$ (skala liniowa) $w_H \in [0,1; 10]$ (skala logarytmiczna)	• Cooldown-Buro_t • UCT_t • UCT-PB-naive_t

Tabela 1: Kaskada strojenia: każdy algorytm trafia do zestawu kontrolnego wszystkich strojonych po nim.

namysłu, krótka ankieta jakościowa (subiektywna trudność, świadomość reguły, poczucie różnicy strategicznej między wariantami). Eksperyment uzupełnia H4 i H5 perspektywą człowieka-gracza i pozwala ocenić, czy strukturalny efekt cooldown jest czytelny dla człowieka.

6.5 Metryki i analiza wyników

Metryki podstawowe: współczynnik wygranych z przedziałem ufności Wilsona, średnia różnica pionków na końcu partii, średnia długość partii, średni czas obliczeń na ruch.

Metryki specyficzne dla reguły stygnięcia. Mierzmy także:

- *whipsaw rate* w klasycznym 6×6 – procent ruchów, które byłyby nielegalne pod regułą stygnięcia, jako miara tego, jak często reguła „by się aktywowała” w klasycznej rozgrywce silnego MCTS,
- *cooldown-blocked move rate* w Cooldown – procent stanów, w których co najmniej jeden potencjalnie atrakcyjny ruch jest zablokowany przez regułę,
- rozkład „długości życia” pionka (ile razy zostaje odwrócony w partii) w obu wariantach – spodziewamy się skróconych ogonów rozkładu na Cooldown.

Analiza statystyczna. Test dwumianowy dla pojedynczych par; test McNemara dla porównań sparowanych po ziarnach (te same ziarna gry dla pary wariantów); korekta Holma–Bonferroniego przy testowaniu wielu hipotez naraz. Wszędzie raportujemy wielkość efektu (różnica we współczynnikach wygranych) wraz z p -value, nie samo p -value.

Wizualizacje. (a) heatmapy współczynnika wygranych w siatce *variant gracza* $\times$ *variant gry*, (b) krzywe skalowania UCT i RAVE z budżetem dla H2, (c) rozkłady różnic pionków na końcu partii (boxplots), (d) wybrane partie pokazane ruch po ruchu, ze szczególnym uwypukleniem ruchów blokowanych regułą stygnięcia.

7 Ogólny projekt techniczny

Implementacja w Pythonie. Logika gry i warianty MCTS pisane od zera; biblioteki pomocnicze: NumPy, SciPy (testy statystyczne i przedziały ufności), Pandas, Matplotlib. Eksperymenty deterministycznie odtwarzalne z ziarna; kod publikowany w publicznym repozytorium git.

Literatura

- [1] Rémi Coulom. Efficient selectivity and backup operators in Monte-Carlo tree search. In *Computers and Games (CG 2006)*, volume 4630 of *Lecture Notes in Computer Science*, pages 72–83. Springer, 2007.
- [2] Cameron B. Browne, Edward Powley, Daniel Whitehouse, Simon M. Lucas, Peter I. Cowling, Philipp Rohlfshagen, Stephen Tavener, Diego Perez, Spyridon Samothrakis, and Simon Colton. A survey of Monte Carlo tree search methods. *IEEE Transactions on Computational Intelligence and AI in Games*, 4(1):1–43, 2012.
- [3] Levente Kocsis and Csaba Szepesvári. Bandit based Monte-Carlo planning. In *Machine Learning: ECML 2006*, volume 4212 of *Lecture Notes in Computer Science*, pages 282–293. Springer, 2006.
- [4] Peter Auer, Nicolò Cesa-Bianchi, and Paul Fischer. Finite-time analysis of the multiarmed bandit problem. *Machine Learning*, 47(2–3):235–256, 2002.
- [5] Sylvain Gelly and David Silver. Monte-Carlo tree search and rapid action value estimation in computer Go. *Artificial Intelligence*, 175(11):1856–1875, 2011.
- [6] Chiara F. Sironi and Mark H. M. Winands. Comparison of rapid action value estimation variants for general game playing. In *2018 IEEE Conference on Computational Intelligence and Games (CIG)*, pages 1–8. IEEE, 2018.
- [7] Guillaume M. J.-B. Chaslot, Mark H. M. Winands, H. Jaap van den Herik, Jos W. H. M. Uiterwijk, and Bruno Bouzy. Progressive strategies for Monte-Carlo tree search. *New Mathematics and Natural Computation*, 4(3):343–357, 2008.
- [8] Benjamin E. Childs, James H. Brodeur, and Levente Kocsis. Transpositions and move groups in Monte Carlo tree search. In *2008 IEEE Symposium on Computational Intelligence and Games*, pages 389–395. IEEE, 2008.
- [9] Michael Buro. An evaluation function for Othello based on statistics. Technical Report 31, NEC Research Institute, 1997.
- [10] Michael Buro. The evolution of strong Othello programs. In *Entertainment Computing: Technologies and Applications*, pages 81–88. Springer, 2003.
- [11] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2623–2631. ACM, 2019.