



Politechnika Warszawska

**Wydział Matematyki
i Nauk Informatycznych**

Metody Sztucznej Inteligencji 2

MCTS/UCT w grze Cooldown Othello 6×6

Autor:

Wojciech Jasiński

Prowadzący:

mgr inż. Bartłomiej Olechno

Warszawa, czerwiec 2026

Streszczenie

Projektujemy i empirycznie analizujemy sztuczną inteligencję do dwuosobowej gry planszowej z pełną informacją, opartą o Monte Carlo Tree Search (MCTS) i jego wariant UCT. Jako grę wybraliśmy Othello na planszy 6×6 z autorską *regułą stygnięcia*: pionki postawione lub odwrócone w poprzedniej turze są chwilowo chronione, co eliminuje natychmiastowe odbijanie (*whipsaw*) i wprowadza do gry zależność od historii. Porównujemy sześciu graczy (losowego, dwie heurystyki pozycyjne Buro i trzy warianty MCTS) na klasycznym Othello 6×6 i na wariantcie z regułą stygnięcia.

Przeprowadziliśmy turniej round-robin (6000 partii przy budżecie 10 000 symulacji na ruch), samogrę najsilniejszego gracza (4000 partii) oraz kaskadowe strojenie hiperparametrów (Optuna TPE). Wyniki: (H1) UCT wyraźnie pokonuje heurystyki, a jego przewaga jest większa pod regułą stygnięcia (88% vs 77% wygranych z Naive-Buro) – *potwierdzona*; (H2) progressive bias daje tylko niewielki zysk i tylko z heurystyką świadomą reguły – z naiwną wręcz szkodzi – *odrzucona*; (H3) heurystyka świadoma reguły jest lepsza w *obu* wariantach, nie tylko pod regułą – *odrzucona*; (H4) strukturalna przewaga drugiego gracza (58% w klasyku) zanika pod regułą stygnięcia (49%) – *potwierdzona*. Najsilniejszym graczem jest UCT-PB-cooldown, ale główny zysk pochodzi z samego MCTS, nie z progressive bias.

Spis treści

1	Wprowadzenie	1
2	Gra i reguła stygnięcia	1
2.1	Othello – zasady klasyczne	1
2.2	Reguła stygnięcia (Cooldown)	1
2.3	Złożoność – weryfikacja empiryczna	2
3	Algorytmy	2
3.1	MCTS i UCT	2
3.2	Progressive bias	2
3.3	Heurystyki Buro	2
4	Gracze	3
5	Hipotezy badawcze	3
6	Metodyka eksperymentu	3
7	Wyniki	4
7.1	Ranking i współczynniki wygranych	4
7.2	Różnice pionków na końcu partii	5
7.3	Metryki specyficzne dla reguły stygnięcia	6
7.4	Strojenie hiperparametrów	7
8	Weryfikacja hipotez	9
9	Podsumowanie i wnioski	9
10	Ograniczenia i odstępstwa od konspektu	10
11	Wykorzystanie dużych modeli językowych	10

1 Wprowadzenie

Celem projektu jest zaprojektowanie i empiryczna analiza AI do dwuosobowej gry z pełną informacją, opartej o MCTS/UCT [8, 3, 9]. Badamy w jakim stopniu klasyczny MCTS oraz ulepszenie *progressive bias* [6] (kierowanie poszukiwań heurystyką dziedzinową) radzą sobie, gdy zmienimy zasady gry w sposób wprowadzający zależność od historii.

Jako grę wybraliśmy Othello – klasyczną grę o prostych zasadach i bogatej literaturze heurystyk pozycyjnych [4, 5] – na zmniejszonej planszy 6×6 , do której wprowadzamy autorską *regulę stygnięcia* (sekcja 2). Reguła zmienia wartość ruchów względem klasyki i pozwala zadać pytanie: czy klasyczne heurystyki i MCTS pozostają skuteczne w zmienionych warunkach, oraz jak modyfikacja wpływa na balans gry.

Raport jest dokumentem samodzielnym: rozdziały 2–5 opisują grę, algorytmy, graczy i hipotezy, a rozdziały 6–9 – przebieg i wyniki rzeczywiście przeprowadzonych eksperymentów.

2 Gra i reguła stygnięcia

2.1 Othello – zasady klasyczne

Othello to deterministyczna gra dwuosobowa z pełną informacją; gracze (czarny i biały, czarny rusza pierwszy) stawiają pionki na planszy, w centrum której leżą początkowo cztery pionki w układzie krzyżowym. Ruch polega na położeniu pionka swojego koloru tak, by w co najmniej jednym kierunku domknął on linię pionków przeciwnika ograniczoną własnym pionkiem; wszystkie domknięte pionki przeciwnika zostają odwrócone na własny kolor. Gracz bez legalnego ruchu pasuje; dwa pasy pod rząd kończą grę. Wygrywa gracz z większą liczbą pionków. Gramy na planszy 6×6 (zamiast 8×8), co redukuje przestrzeń stanów o kilkanaście rzędów wielkości i umożliwia statystycznie wiarygodne porównania wielu wariantów MCTS, zachowując elementy strategii Othello.

2.2 Reguła stygnięcia (Cooldown)

Stan gry to para (B, C) , gdzie B to konfiguracja planszy, a C to zbiór pól ze znacznikiem *stygnięcia* – pionków postawionych lub odwróconych w bezpośrednio poprzedniej turze. Pionek ze znacznikiem jest *przezroczysty*: nie kończy linii domykania, nie czyni jej nielegalną i nie może zostać odwrócony w tej turze.

Legalność. Stawiając pionek na pustym polu p , dla każdego z 8 kierunków idziemy od p : puste pole lub krawędź odrzuca linię; pionek własnego koloru zamyka linię, która jest akceptowana *wtedy i tylko wtedy*, gdy po drodze wystąpił co najmniej jeden pionek przeciwnika *bez* znacznika stygnięcia. Ruch jest legalny, jeśli istnieje co najmniej jedna akceptowana linia.

Egzekucja. Po legalnym ruchu: (1) zdejmujemy wszystkie znaczniki ($C \leftarrow \emptyset$), (2) stawiamy pionek na p , (3) w akceptowanych liniach odwracamy tylko pionki przeciwnika *bez* znacznika (ostudzone zostają w swoim kolorze), (4) nowy zbiór C to pole p wraz z wszystkimi właśnie odwróconymi pionkami. Pas wykonuje wyłącznie krok (1). Przypadki graniczne: świeżo postawiony pionek też trafia do C (jest chroniony przez jedną

ture); ostudzone pionki w linii mieszanej przepuszczamy przezroczyście; pas zeruje C (znaczniki się nie kumulują).

Po co ta reguła. W klasycznym Othello *whipsaw* – naprzemienne odwracanie tych samych pionków – jest częstą taktyką. Reguła stygnięcia eliminuje natychmiastowe odwzajemnienie i wprowadza *zależność od historii*: legalność ruchu zależy nie tylko od planszy, ale i od pionków odwróconych w poprzedniej turze. Skutki istotne dla badania: (i) MCTS musi reprezentować stan jako parę (**plansza**, **ostudzone**), więc dwie identyczne fizycznie pozycje nie są tożsame, co osłabia tablice transpozycji [7]; (ii) klasyczne wagi Buro, skalibrowane dla swobodnego bicia, nie uwzględniają chwilowej ochrony odwracanych pionków.

2.3 Złożoność – weryfikacja empiryczna

Przed głównymi eksperymentami zmierzaliśmy długość gry i rozgałęzienie w 1000 partiach losowych na wariant. Reguła stygnięcia **obniża średnie rozgałęzienie** z 5,3 (klasyk) do 4,5 (cooldown), bo część bić jest zablokowana, ale **nie skraca gry**: średnia długość wynosi ≈ 34 półruchy w obu wariantach, bo plansza i tak się zapełnia. (Konspekt szacował długość Cooldown na ~ 28 ; pomiar pokazał wartość wyższą – por. sekcja 10.) Iloczyn rozgałęzienia i długości mieści się w zakładanej skali złożoności dla rzetelnych porównań MCTS.

3 Algorytmy

3.1 MCTS i UCT

Monte Carlo Tree Search buduje drzewo gry z powtarzanych iteracji, z których każda ma cztery fazy: *selekcja* (zejście od korzenia po drzewie wg polityki balansującej eksplorację i eksploatację), *ekspansja* (dodanie nowego węzła), *symulacja* (losowe rozegranie do końca) i *backpropagacja* (uaktualnienie statystyk węzłów na ścieżce wynikiem symulacji). UCT [9] w selekcji wybiera ruch maksymalizujący górną granicę ufności UCB1 [2]:

$$\text{UCB1}(s, a) = \bar{Q}(s, a) + c \sqrt{\frac{\ln N(s)}{N(s, a)}},$$

gdzie $\bar{Q}$ to średnia wygrana, N – liczniki odwiedzin, c – stała eksploracji, a budżet B – liczba iteracji na ruch. Węzeł przechowuje pełny stan (B, C) ; z powodu zależności od historii nie stosujemy tablic transpozycji.

3.2 Progressive bias

Progressive bias [6] dodaje do UCB1 człon $w_H H(s, a)/(N(s, a)+1)$, gdzie H to heurystyka dziedzinowa, a w_H – jej waga. Przy małej liczbie odwiedzin heurystyka silnie kieruje wyborem; wraz ze wzrostem N jej wpływ maleje, a dominują dane z symulacji.

3.3 Heurystyki Buro

Klasyczna heurystyka pozycyjna Buro [4] łączy dwa składniki. *Wagi pozycyjne*: każdemu polu przypisana jest waga – rogi cenne (+100, są stabilne), pola X (skośnie przy rogu) silnie ujemne (−50), pola C (przy rogu) ujemne (−20), brzeg dodatni (+10), wewnątrz nieznacznie ujemne; wartość pozycji to suma wag pól gracza minus przeciwnika. *Mobilność*:

różnica liczby legalnych ruchów obu graczy, z wagą w_{mob} . Heurystyczny gracz wybiera ruch maksymalizujący ważoną sumę po jednym ruchu w przód (negamax głębokości 1).

Cooldown-Buro rozszerza powyższą ocenę o człon (waga λ_c) świadomy reguły stygnięcia: *kara* za każdy odwracany pionek, który po wygaśnięciu cooldown przeciwnik łatwo odbije, oraz *bonus* za pionek osłonięty z obu stron własnymi pionkami (trwale stabilny). Naive-Buro używa tylko klasycznej części; Cooldown-Buro – pełnej rozszerzonej oceny.

4 Gracze

Porównujemy sześciu graczy: **Random** (losowy legalny ruch – punkt odniesienia); **Naive-Buro** i **Cooldown-Buro** (negamax 1-warstwowy, odpowiednio z klasyczną i rozszerzoną oceną); **UCT** (bazowy MCTS); **UCT-PB-naive** i **UCT-PB-cooldown** (UCT z progressive bias, kierowany odpowiednio naiwną i świadomą reguły heurystyką). Random, Naive-Buro i UCT to punkty kontrolne; UCT-PB-cooldown to typowany najsilniejszy gracz.

5 Hipotezy badawcze

- H1** UCT pokonuje Naive-Buro w obu wariantach ($\geq 60\%$ na Cooldown), a jego przewaga jest istotnie większa na Cooldown niż na klasyku.
- H2** UCT+progressive-bias z Cooldown-Buro pokonuje bazowy UCT na Cooldown o ≥ 10 p.p., wyraźniej niż wariant z naiwną heurystyką.
- H3** Cooldown-Buro pokonuje Naive-Buro na Cooldown (≥ 10 p.p.), ale na klasyku obie są praktycznie równoważne (< 5 p.p.).
- H4** Strukturalna przewaga drugiego gracza w klasycznym 6×6 zanika pod regułą stygnięcia (badana w samogrze najsilniejszego wariantu).

6 Metodyka eksperymentu

Turniej (H1–H3). Dla obu wariantów gry rozegraliśmy turniej round-robin między sześcioma graczami: każda z 15 par zagrała 200 partii z zamianą kolorów (po 100 na kolor), przy budżecie $B = 10\,000$ symulacji na ruch. Daje to $15 \times 200 \times 2 = \mathbf{6000}$ partii.

Samogra (H4). Najsilniejszy wariant (UCT-PB-cooldown) zagrał sam ze sobą po 2000 partii na wariant gry (łącznie 4000), z odrębnymi ziarnami dla obu kolorów, by uniknąć identycznych rozegrań. Raportujemy współczynnik wygranych drugiego gracza (białego).

Strojenie hiperparametrów. Hiperparametry dobrano biblioteką Optuna (sampler TPE) [1], kaskadowo: każdy ustrojony gracz wchodził do zestawu kontrolnego graczy strojonych po nim. Funkcją celu był średni współczynnik wygranych wobec trzech przeciwników kontrolnych; budżet strojenia $B_{\text{tune}} = 2000$, 30 prób na algorytm, 60 partii na próbę. Heurystyki strojono raz (na Cooldown) i reużyto w obu wariantach; warianty MCTS strojono osobno na każdym wariancie gry. Końcowe wartości zebrano w tabeli 2.

Maszyna i czas. Eksperymenty uruchomiono na wynajętej maszynie CPU (128 rdzeni, 1 TiB RAM, Python 3.12); obliczenia zrównoleglono na poziomie partii (`multiprocessing`). Strojenie zajęło ok. 48 min, a turniej i samogra przy $B = 10\,000$ – kilkadziesiąt minut; pojedyncza partia dwóch graczy MCTS przy $B = 10\,000$ trwa ok. 70 s. GPU nie jest tu przydatne (przeszukiwanie drzewa jest sekwencyjne), więc skalujemy liczbą rdzeni.

Analiza statystyczna. Współczynniki wygranych raportujemy z 95% przedziałem ufności Wilsona; istotność: test dwumianowy (pojedyncze pary) i test McNemara (porównania sparowane po ziarnach), z korektą Holma–Bonferroniego dla rodziny hipotez. Remis liczymy jako pół wygranej.

Implementacja. Silnik gry i warianty MCTS napisano od zera w Pythonie (NumPy/SciPy/Pandas/Matplotlib, Optuna); poprawność reguł potwierdzono testami jednostkowymi oraz testem różnicowym (zgodność generatora ruchów z niezależną implementacją na 4144 pozycjach). Każda partia jest odtwarzalna z ziaren; kod jest publiczny, a wyniki zapisywane przyrostowo (wznawialnie).


7 Wyniki

7.1 Ranking i współczynniki wygranych

Na podstawie 6000 partii turniejowych (po 3000 na wariant) tabela 1 i rysunek 1 podają średni współczynnik wygranych każdej metody, uśredniony po wszystkich jej partiach. W obu wariantach MCTS zdecydowanie przewyższa heurystyki. Najsilniejszy jest **UCT-PB-cooldown**, jako jedyny utrzymujący wysoki wynik w obu wariantach (0,84/0,81). Ciekawe są dwa zjawiska: UCT-PB-naive jest mocny na klasyku (0,86), ale *załamuje się* pod regułą stygnięcia (0,64) – naiwna heurystyka myli poszukiwanie; bazowy UCT przeciwnie – jest *lepszy* pod regułą (0,79) niż na klasyku (0,63).


Metoda	śr. WR klasyk	śr. WR cooldown	średnia
UCT-PB-cooldown	0.844	0.814	0.829
UCT-PB-naive	0.859	0.644	0.752
UCT	0.632	0.788	0.710
Cooldown-Buro	0.346	0.424	0.385
Naive-Buro	0.279	0.278	0.278
Random	0.040	0.052	0.046

Tabela 1: Ranking: średni współczynnik wygranych każdej metody, uśredniony po wszystkich jej partiach turniejowych (po obu kolorach i wszystkich przeciwnikach).



Rysunek 1: Średni współczynnik wygranych metod na obu wariantach gry (te same dane co tab. 1).


Pełną strukturę par pokazują heatmapy współczynników wygranych (rys. 2): wartość to odsetek wygranych gracza z wiersza przeciw graczowi z kolumny.



Rysunek 2: Współczynnik wygranych gracza w wierszu przeciw graczowi w kolumnie.

7.2 Różnice pionków na końcu partii


Rysunek 3 pokazuje rozkłady różnicy pionków na końcu partii (z perspektywy danej metody). Silniejsze metody nie tylko wygrywają częściej, ale i wyraźniejszą przewagą pionków; heurystyki i gracz losowy mają mediany ujemne lub bliskie zera.



Rysunek 3: Różnica pionków na końcu partii (metoda – przeciwnik), wg metody i wariantu.

7.3 Metryki specyficzne dla reguły stygnięcia

Aby zmierzyć, jak często reguła w ogóle „działa”, liczymy dwie wielkości (rys. 4). *Whipsaw rate* (partie klasyczne) to odsetek faktycznie zagrzanych ruchów, które byłyby *nielegalne* pod regułą stygnięcia – mierzy, jak często w normalnej grze padają natychmiastowe odbicia, które reguła by zablokowała. *Cooldown-blocked rate* (partie Cooldown) to odsetek decyzji, w których co najmniej jeden ruch legalny w klasyce jest zablokowany przez regułę. Obie metryki mierzą *częstość aktywacji* reguły, a nie jakość zablokowanego ruchu – nie twierdzimy, że zablokowany ruch jest „dobry”; pokazujemy jedynie, że reguła realnie ingeruje w grę (mediana kilkunastu procent decyzji).




(a) Klasyk: jak często padają natychmiastowe odbicia. (b) Cooldown: jak często reguła blokuje ruch legalny w klasyce.

Rysunek 4: Częstość aktywacji reguły. Metryki mierzą, jak często reguła *ingeruje* w grę, a nie jakość zablokowanego ruchu.

Bardziej bezpośrednim skutkiem reguły jest „długość życia” pionka – ile razy dane pole

zostaje odwrócone w partii (rys. 5). Pod regułą stygnięcia rozkład ma *krótszy ogon*: pionki są rzadziej wielokrotnie odbijane, bo świeże bicia są chwilowo chronione – co jest istotą modyfikacji.




Rysunek 5: Rozkład „długości życia” pionka – maksymalnej liczby odwróceń pojedynczego pola w partii. Pod regułą stygnięcia rozkład ma krótszy ogon.

7.4 Strojenie hiperparametrów


Końcowe hiperparametry zebrano w tabeli 2. Najciekawsza obserwacja: stała eksploracji c dla UCT wypada po przeciwnych stronach zakresu dla obu wariantów (2,23 klasyk vs 0,52 cooldown). Rysunek 6 wyjaśnia dlaczego – zależność funkcji celu od c jest prawie płaska: silny UCT i tak pokonuje (słaby dla niego) zestaw kontrolny, więc współczynnik wygranych nasycza się i c jest słabo ograniczone (na Cooldown widać dodatkowo łagodną preferencję małego c). Dla wariantów z progressive bias zależność jest wyraźniejsza – niski c idzie w parze z wysokim w_H (silne kierowanie heurystyką zastępuje eksplorację UCB), co najlepiej widać dla UCT-PB-cooldown na Cooldown ($c=0,54$, $w_H=8,7$).

Metoda	Wariant	c	w_{mob}	λ_c	w_H	WR (strojenie)
Naive-Buro	oba*	–	4.75	–	–	0.583
Cooldown-Buro	oba*	–	2.49	0.52	–	0.708
UCT	classic	2.23	–	–	–	0.958
UCT	cooldown	0.52	–	–	–	0.950
UCT-PB-naive	classic	0.75	–	–	2.42	0.933
UCT-PB-naive	cooldown	1.11	–	–	1.12	0.842
UCT-PB-cooldown	classic	0.72	–	–	5.02	0.817
UCT-PB-cooldown	cooldown	0.54	–	–	8.71	0.717

Tabela 2: Końcowe hiperparametry po strojeniu (Optuna TPE) oraz współczynnik wygranych wobec zestawu kontrolnego. *heurystyki strojono raz na Cooldown i reużyto w obu wariantach gry.



Rysunek 6: Zależność celu strojenia od stałej eksploracji c (PDP/slice; każdy punkt to jedna próba Optuny). Czerwona linia przerywana – najlepsze c , szara kropkowana – $\sqrt{2}$ (literatura). Funkcja jest niemal płaska, więc c jest słabo ograniczone.



Rysunek 7: Zależność celu od hiperparametrów dla wybranych metod (PDP/slice). Dla UCT-PB-cooldown widać realną zależność od c i w_H ; dla heurystyki Cooldown-Buro funkcja jest niemal płaska względem λ_c i w_{mob} (parametry słabo ograniczone).

8 Weryfikacja hipotez

Hipoteza	Wynik	kluczowy efekt	p	holm- p
H1	potwierdzona	UCT vs Naive-Buro: 0.88 cooldown / 0.77 klasyk	0.000	0.000
H2	odrzucona	przewaga UCT-PB-cooldown nad UCT: 4 p.p.	0.289	0.289
H3	odrzucona	Cooldown-Buro vs Naive-Buro: 50 p.p. cooldown / 26 p.p. klasyk	0.000	0.000
H4	potwierdzona	biały (2. gracz): 0.58 klasyk / 0.49 cooldown	0.000	0.000

Tabela 3: Weryfikacja hipotez (wielkość efektu, p -wartość testu i p po korekcie Holma–Bonferroniego).

H1 – potwierdzona. UCT pokonuje Naive-Buro w 88% partii na Cooldown (95% CI: 0,82–0,92; $\geq 60\%$) i w 77% na klasyku; przewaga jest o ok. 11 p.p. większa pod regułą stygnięcia ($p \approx 10^{-29}$). Zgodnie z intuicją: reguła komplikuje ocenę pozycyjną, a MCTS lepiej radzi sobie z zależnością od historii.

H2 – odrzucona. UCT-PB-cooldown pokonuje bazowy UCT na Cooldown jedynie o ok. 4 p.p. (próg 10 p.p. nieosiągnięty, różnica nieistotna), a UCT-PB-naive wręcz *przegrywa* z bazowym UCT. Progressive bias pomaga więc tylko z heurystyką świadomą reguły i to nieznacznie, a z naiwną szkodzi.

H3 – odrzucona. Na Cooldown Cooldown-Buro pokonuje Naive-Buro w 100% (przewaga $\gg 10$ p.p.), ale na klasyku również wygrywa (o ok. 26 p.p.), zamiast być równoważna. Heurystyka świadoma reguły jest po prostu lepsza w obu wariantach – jej człon „trwałości bicia” jest użyteczny także w klasycznym Othello – więc nie udało się wyizolować efektu samej reguły.

H4 – potwierdzona. W samogrze (po 2000 partii na wariant) drugi gracz wygrywa 58,4% partii na klasyku (95% CI: 0,562–0,605; istotnie $> 50\%$), ale tylko 49,1% pod regułą stygnięcia (95% CI: 0,469–0,513; nieodróżnialne od 50%). Strukturalna przewaga drugiego gracza istnieje w klasyku i *zanika* pod regułą – whipsaw jest taktyką reaktywną, więc jego eliminacja odbiera przewagę graczowi odpowiadającemu.

9 Podsumowanie i wnioski

Spośród czterech hipotez potwierdziły się dwie (H1, H4), a dwie odrzuciliśmy (H2, H3); odrzucenia są pouczające, nie negatywne. Najważniejsze wnioski:

- **Zysk pochodzi z MCTS, nie z progressive bias.** UCT-PB-cooldown jest najsilniejszy, ale jego przewaga nad bazowym UCT jest niewielka; dodatkowo naiwna heurystyka w progressive bias *szkodzi* pod regułą (UCT-PB-naive: 0,86 klasyk $\rightarrow$ 0,64 cooldown).
- **Świadomość reguły ma znaczenie dla heurystyki.** Cooldown-Buro miażdży Naive-Buro pod regułą (100%); naiwna ocena prowadzi do bić, które reguła karze (zapaść Naive-Buro).
- **Heurystyka „trwałości bicia” jest ogólnie wartościowa** – pomaga także w klasyku, a nie tylko pod regułą (stąd odrzucenie H3 jako hipotezy o izolacji efektu).

- **Reguła zmienia balans gry** – znika strukturalna przewaga drugiego gracza (H4), więc Cooldown Othello jest wariantem bardziej zrównoważonym, a jednocześnie realnie ingeruje w grę (krótszy ogon „długości życia” pionków, kilkanaście procent zablokowanych decyzji).
- **MCTS lubi tę regułę** – bazowy UCT radzi sobie *lepiej* pod regułą niż na klasyku względem pola, co wzmacnia obraz z H1.

10 Ograniczenia i odstępstwa od konspektu

- **Długość gry.** Konspekt szacował średnią długość Cooldown na ~ 28 ruchów; pomiar (1000 partii losowych) dał ≈ 34 – plansza zapelnia się niezależnie od reguły. To korekta szacunku, nie zmiana planu.
- **Strojenie c słabo ograniczone.** Dla silnych graczy funkcja celu strojenia nasycza się (zestawy kontrolne są dla nich za słabe), więc część hiperparametrów MCTS jest słabo określona (rys. 6). Wzmocnienie zestawów kontrolnych to naturalny kierunek poprawy.
- **Eksperyment człowiek–komputer** przewidziany w konspekcie *nie został* przeprowadzony w tej iteracji; przygotowano natomiast działający interfejs webowy gry, gotowy do takiego badania.

11 Wykorzystanie dużych modeli językowych

Projekt zrealizowano z użyciem asystenta opartego o duży model językowy (Claude, Anthropic) w roli pary programistycznej: implementacja silnika gry i wariantów MCTS, skryptów strojenia i analizy, orkiestracja eksperymentów na maszynie zdalnej oraz redakcja raportu. Wszystkie decyzje projektowe, weryfikacja poprawności (testy jednostkowe i różnicowe) oraz interpretacja wyników były nadzorowane przez autora.

Literatura

- [1] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2623–2631. ACM, 2019.
- [2] Peter Auer, Nicolò Cesa-Bianchi, and Paul Fischer. Finite-time analysis of the multiarmed bandit problem. *Machine Learning*, 47(2–3):235–256, 2002.
- [3] Cameron B. Browne, Edward Powley, Daniel Whitehouse, Simon M. Lucas, Peter I. Cowling, Philipp Rohlfshagen, Stephen Tavener, Diego Perez, Spyridon Samothrakis, and Simon Colton. A survey of Monte Carlo tree search methods. *IEEE Transactions on Computational Intelligence and AI in Games*, 4(1):1–43, 2012.
- [4] Michael Buro. An evaluation function for Othello based on statistics. Technical Report 31, NEC Research Institute, 1997.
- [5] Michael Buro. The evolution of strong Othello programs. In *Entertainment Computing: Technologies and Applications*, pages 81–88. Springer, 2003.

- [6] Guillaume M. J.-B. Chaslot, Mark H. M. Winands, H. Jaap van den Herik, Jos W. H. M. Uiterwijk, and Bruno Bouzy. Progressive strategies for Monte-Carlo tree search. *New Mathematics and Natural Computation*, 4(3):343–357, 2008.
- [7] Benjamin E. Childs, James H. Brodeur, and Levente Kocsis. Transpositions and move groups in Monte Carlo tree search. In *2008 IEEE Symposium on Computational Intelligence and Games*, pages 389–395. IEEE, 2008.
- [8] Rémi Coulom. Efficient selectivity and backup operators in Monte-Carlo tree search. In *Computers and Games (CG 2006)*, volume 4630 of *Lecture Notes in Computer Science*, pages 72–83. Springer, 2007.
- [9] Levente Kocsis and Csaba Szepesvári. Bandit based Monte-Carlo planning. In *Machine Learning: ECML 2006*, volume 4212 of *Lecture Notes in Computer Science*, pages 282–293. Springer, 2006.