



Politechnika Warszawska

**Wydział Matematyki
i Nauk Informatycznych**

Metody Sztucznej Inteligencji 2

MCTS/UCT w grze Cooldown Othello 6×6

Autor:

Wojciech Jasiński

Prowadzący:

mgr inż. Bartłomiej Olechno

Warszawa, czerwiec 2026

Streszczenie

Projektujemy i empirycznie analizujemy sztuczną inteligencję do dwuosobowej gry planszowej z pełną informacją, opartą o Monte Carlo Tree Search (MCTS) i jego wariant UCT. Jako grę wybraliśmy Othello na planszy 6×6 z autorską *regułą stygnięcia*: pionki postawione lub odwrócone w poprzedniej turze są chwilowo chronione, co eliminuje natychmiastowe odbijanie (*whipsaw*) i wprowadza do gry zależność od historii. Porównujemy sześciu graczy – losowego, dwie proste heurystyki pozycyjne inspirowane literaturą Othello oraz trzy warianty MCTS (w tym z *progressive bias*) – w turnieju, samogrze i po strojeniu hiperparametrów, na obu wariantach gry.

Główne wnioski: MCTS wyraźnie przewyższa heurystyki, a jego przewaga rośnie pod regułą stygnięcia; *progressive bias* daje co najwyżej niewielki zysk i tylko z heurystyką świadomą reguły (z naiwną szkodzi); heurystyka świadoma reguły jest lepsza w obu wariantach, nie tylko pod regułą; reguła zmienia balans gry – obserwowana w klasyku przewaga drugiego gracza zanika. Najsilniejszym graczem (uśredniając oba warianty) jest UCT-PB-cooldown, lecz główny zysk pochodzi z samego MCTS, nie z *progressive bias*. Uzupełniając przeprowadziliśmy nieformalny test człowiek–komputer: gra okazała się trudna dla początkujących, a najsilniejszego agenta nie pokonał żaden z grających.

Spis treści

1	Wprowadzenie	1
2	Gra i reguła stygnięcia	1
2.1	Othello – zasady klasyczne	1
2.2	Reguła stygnięcia (Cooldown)	1
2.3	Złożoność – weryfikacja empiryczna	3
3	Algorytmy	3
3.1	MCTS i UCT	3
3.2	Progressive bias	3
3.3	Heurystyki pozycyjne (inspirowane Buro)	4
4	Gracze	4
5	Hipotezy badawcze	4
6	Metodyka eksperymentu	4
7	Wyniki	5
7.1	Ranking i współczynniki wygranych	5
7.2	Różnice pionków na końcu partii	6
7.3	Metryki specyficzne dla reguły stygnięcia	7
7.4	Strojenie hiperparametrów	8
8	Weryfikacja hipotez	11
9	Eksperyment człowiek–komputer	11
10	Podsumowanie i wnioski	12
11	Wykorzystanie dużych modeli językowych	13

1 Wprowadzenie


Celem projektu jest zaprojektowanie i empiryczna analiza AI do dwuosobowej gry z pełną informacją, opartej o MCTS/UCT [8, 3, 10]. Badamy w jakim stopniu klasyczny MCTS oraz ulepszenie *progressive bias* [6] (kierowanie poszukiwań heurystyką dziedzinową) radzą sobie, gdy zmienimy zasady gry w sposób wprowadzający zależność od historii.

Jako grę wybraliśmy Othello – klasyczną grę o prostych zasadach i bogatej literaturze heurystyk pozycyjnych [4, 5] – na zmniejszonej planszy 6×6 , do której wprowadzamy autorską *regułę stygnięcia* (sekcja 2). Reguła zmienia wartość ruchów względem klasyki i pozwala zadać pytanie: czy klasyczne heurystyki i MCTS pozostają skuteczne w zmienionych warunkach, oraz jak modyfikacja wpływa na balans gry.

2 Gra i reguła stygnięcia

2.1 Othello – zasady klasyczne

Othello to deterministyczna gra dwuosobowa z pełną informacją; gracze (czarny i biały, czarny rusza pierwszy) stawiają pionki na planszy, w centrum której leżą początkowo cztery pionki w układzie krzyżowym. Ruch polega na położeniu pionka swojego koloru tak, by w co najmniej jednym kierunku domknął on linię pionków przeciwnika ograniczoną własnym pionkiem; wszystkie domknięte pionki przeciwnika zostają odwrócone na własny kolor. Gracz bez legalnego ruchu pasuje; dwa pasy pod rząd kończą grę. Wygrywa gracz z większą liczbą pionków. Gramy na planszy 6×6 (zamiast 8×8), co redukuje przestrzeń stanów o kilkanaście rzędów wielkości i umożliwia statystycznie wiarygodne porównania wielu wariantów MCTS, zachowując elementy strategii Othello. Zasady ilustruje rysunek 1 (pozycja startowa, przykład w środkowej fazie gry oraz pozycja końcowa).



Rysunek 1: Othello 6×6 . (a) Pozycja startowa: cztery pionki w układzie krzyżowym w centrum (biały na przekątnej głównej, czarny na przeciwprzekątnej), czarny wykonuje pierwszy ruch. (b) Przykładowa pozycja w środkowej fazie gry; przerywane okręgi zaznaczają wszystkie legalne ruchy strony na ruchu (czarnego). (c) Pozycja końcowa z rzeczywistej partii człowiek-komputer: po wypełnieniu planszy wygrywa strona z większą liczbą pionków (tu komputer 19:17).


2.2 Reguła stygnięcia (Cooldown)

Stan gry to para (B, C) , gdzie B to konfiguracja planszy, a C to zbiór pól ze znacznikiem *stygnięcia* – pionków postawionych lub odwróconych w bezpośrednio poprzedniej

turze. Pionek ze znacznikiem jest *przezroczysty*: nie kończy linii domykania, nie czyni jej nielegalną i nie może zostać odwrócony w tej turze.

Legalność. Stawiając pionek na pustym polu p , dla każdego z 8 kierunków idziemy od p : puste pole lub krawędź odrzuca linię; pionek własnego koloru zamyka linię, która jest akceptowana *wtedy i tylko wtedy*, gdy po drodze wystąpił co najmniej jeden pionek przeciwnika *bez* znacznika stygnięcia. Ruch jest legalny, jeśli istnieje co najmniej jedna akceptowana linia. Co istotne, znacznik stygnięcia nie przerywa skanowania linii: ostudzony pionek przeciwnika jest *pomijany* (nie blokuje i nie domyka linii), a odwracane są wyłącznie nieostudzone pionki przeciwnika leżące na zaakceptowanej linii – bicie może więc być *nieciągłe*. Ruch, który łamałby regułę, jest po prostu *niedostępny* – silnik usuwa go ze zbioru legalnych ruchów; nie ma osobnego mechanizmu *kary*. Gracz zawsze wybiera wyłącznie spośród ruchów legalnych, więc „zapaść” gracza naiwnego (sekcja 8) wynika nie z karania ruchów, lecz z grania legalnych bić, które reguła czyni strategicznie kruchymi.

Egzekucja. Po legalnym ruchu: (1) zdejmujemy wszystkie znaczniki ($C \leftarrow \emptyset$), (2) stawiamy pionek na p , (3) w akceptowanych liniach odwracamy tylko pionki przeciwnika *bez* znacznika (ostudzone zostają w swoim kolorze), (4) nowy zbiór C to pole p wraz z wszystkimi właśnie odwróconymi pionkami. Pas wykonuje wyłącznie krok (1). Przypadki graniczne: świeżo postawiony pionek też trafia do C (jest chroniony przez jedną turę); ostudzone pionki w linii mieszanej przepuszczamy przezroczystości; pas zeruje C (znaczniki się nie kumulują). Rysunek 2 pokazuje regułę w działaniu na małym przykładzie.




Rysunek 2: Działanie reguły stygnięcia. (a) Czarny wykonuje normalne bicie. (b) Postawiony i właśnie odwrócone pionki dostają znacznik stygnięcia (pomarańczowy pierścień) i są chronione przez jedną turę. (c) Biały chciałby natychmiast odbić środkowy pionek z góry (między swoimi pionkami), ale ostudzony pionek jest *przezroczysty* – linia nie domyka żadnego bicia, więc ten ruch jest nielegalny. Tak reguła eliminuje *whipsaw* (natychmiastowe odwzajemnienie).

Po co ta reguła. W klasycznym Othello *whipsaw* – naprzemienne odwracanie tych samych pionków – jest częstą taktyką. Reguła stygnięcia eliminuje natychmiastowe odwzajemnienie i wprowadza *zależność od historii*: legalność ruchu zależy nie tylko od planszy, ale i od pionków odwróconych w poprzedniej turze. Skutki istotne dla badania: (i) MCTS musi reprezentować stan jako parę (**plansza**, **ostudzone**), więc dwie identyczne fizycznie pozycje nie są tożsame, co osłabia proste tablice transpozycji oparte na samej konfiguracji planszy [7]; (ii) klasyczne wagi Buro, skalibrowane dla swobodnego bicia, nie uwzględniają chwilowej ochrony odwracanych pionków.

2.3 Złożoność – weryfikacja empiryczna

Przed głównymi eksperymentami zmierzaliśmy długość gry i rozgałęzienie w 1000 partiach losowych na wariant. Reguła stygnięcia **obniża średnie rozgałęzienie** z 5,3 (klasyk) do 4,5 (cooldown), bo część bić jest zablokowana, ale **nie skraca gry**: średnia długość to ≈ 34 –35 pólruchów w obu wariantach (rys. 3 pokazuje rozkład w turnieju), bo gra zwykle dochodzi niemal do zapełnienia planszy (średnio ok. 31,7 z 32 możliwych postawień). Jest to odstępstwo od konspektu, który szacował długość Cooldown na ~ 28 – to korekta wcześniejszego oszacowania, nie zmiana planu. Iloczyn rozgałęzienia i długości mieści się w zakładanej skali złożoności dla rzetelnych porównań MCTS.



Rysunek 3: Rozkład długości partii (liczba pólruchów) w obu wariantach. Reguła stygnięcia *nie skraca* gry – plansza i tak się zapełnia – a mediana (≈ 35) jest wyższa niż zakładane w konspekcie ~ 28 .

3 Algorytmy

3.1 MCTS i UCT

Monte Carlo Tree Search buduje drzewo gry z powtarzanych iteracji, z których każda ma cztery fazy: *selekcja* (zejście od korzenia po drzewie wg polityki balansującej eksplorację i eksploatację), *ekspansja* (dodanie nowego węzła), *symulacja* (losowe rozegranie do końca) i *backpropagacja* (uaktualnienie statystyk węzłów na ścieżce wynikiem symulacji). UCT [10] w selekcji wybiera ruch maksymalizujący górną granicę ufności UCB1 [2]:

$$\text{UCB1}(s, a) = \bar{Q}(s, a) + c \sqrt{\frac{\ln N(s)}{N(s, a)}},$$

gdzie $\bar{Q}$ to średnia wygrana, N – liczniki odwiedzin, c – stała eksploracji, a budżet B – liczba iteracji na ruch. Węzeł przechowuje pełny stan gry (plansza, znaczniki stygnięcia, gracz na ruchu, licznik pasów); z powodu zależności od historii nie stosujemy tablic transpozycji. Wartość $\bar{Q}(s, a)$ utrzymujemy z perspektywy gracza na ruchu w danym węźle – w backpropagacji każdy węzeł aktualizujemy wynikiem symulacji liczonym z jego perspektywy (równoważnie: negamax ze zmianą znaku co poziom drzewa).

3.2 Progressive bias

Progressive bias [6] dodaje do UCB1 człon $w_H H(s, a)/(N(s, a)+1)$, gdzie H to heurystyka dziedzinowa, a w_H – jej waga. Wartości $H(s, a)$ normalizujemy min-max do $[0, 1]$ w obrębie legalnych ruchów danego węzła, dzięki czemu waga w_H jest porównywalna między

heurystykami o różnych skalach. Przy małej liczbie odwiedzin heurystyka silnie kieruje wyborem; wraz ze wzrostem N jej wpływ maleje, a dominują dane z symulacji.

3.3 Heurystyki pozycyjne (inspirowane Buro)

Nasza heurystyka pozycyjna to *uproszczona*, ręcznie dobrana ocena inspirowana klasycznymi cechami Othello z prac Buro [4, 5] (a nie odtworzeniem jego *uczonej* funkcji oceny Logistello). Łączy dwa składniki. *Wagi pozycyjne*: ręcznie ustalona tablica wag pól – rogi cenne (+100, są stabilne), pola X (skośnie przy rogu) silnie ujemne (−50), pola C (przy rogu) ujemne (−20), brzeg dodatni (+10), wewnątrz nieznacznie ujemne; wartość pozycji to suma wag pól gracza minus przeciwnika. *Mobilność*: różnica liczby legalnych ruchów obu graczy, z wagą w_{mob} . Heurystyczny gracz wybiera ruch maksymalizujący ważoną sumę po jednym ruchu w przód (negamax głębokości 1).

Cooldown-Buro rozszerza powyższą ocenę o człon (waga λ_c) świadomy reguły stygnięcia: *kara* za każdy odwracany pionek, który po wygaśnięciu cooldown przeciwnik łatwo odbije, oraz *bonus* za pionek osłonięty z obu stron własnymi pionkami (trwale stabilny). Naive-Buro używa tylko klasycznej części; Cooldown-Buro – pełnej rozszerzonej oceny.

4 Gracze

Porównujemy sześciu graczy: **Random** (losowy legalny ruch – punkt odniesienia); **Naive-Buro** i **Cooldown-Buro** (negamax 1-warstwowy, odpowiednio z klasyczną i rozszerzoną oceną); **UCT** (bazowy MCTS); **UCT-PB-naive** i **UCT-PB-cooldown** (UCT z progressive bias, kierowany odpowiednio naiwną i świadomą regułą heurystyką). Random, Naive-Buro i UCT to punkty kontrolne; UCT-PB-cooldown to typowany najsilniejszy gracz.

5 Hipotezy badawcze

- H1** UCT pokonuje Naive-Buro w obu wariantach ($\geq 60\%$ na Cooldown), a jego przewaga jest istotnie większa na Cooldown niż na klasyku.
- H2** UCT+progressive-bias z Cooldown-Buro pokonuje bazowy UCT na Cooldown o ≥ 10 p.p., wyraźniej niż wariant z naiwną heurystyką.
- H3** Cooldown-Buro pokonuje Naive-Buro na Cooldown (≥ 10 p.p.), ale na klasyku obie są praktycznie równoważne (< 5 p.p.).
- H4** Strukturalna przewaga drugiego gracza w klasycznym 6×6 zanika pod regułą stygnięcia (badana w samogrze najsilniejszego wariantu).

6 Metodyka eksperymentu

Turniej (H1–H3). Dla obu wariantów gry rozegraliśmy turniej round-robin między sześcioma graczami: każda z 15 par zagrała 200 partii z zamianą kolorów (po 100 na kolor), przy budżecie $B = 10\,000$ symulacji na ruch. Daje to $15 \times 200 \times 2$, czyli **6000** partii.

Samogra (H4). Najsilniejszy wariant (UCT-PB-cooldown) zagrał sam ze sobą po 2000 partii na wariant gry (łącznie 4000), z odrębnymi ziarnami dla obu kolorów, by uniknąć identycznych rozegrań. Raportujemy współczynnik wygranych drugiego gracza (białego).

Strojenie hiperparametrów. Hiperparametry dobrano biblioteką Optuna (sampler TPE) [1], kaskadowo: każdy ustrojony gracz wchodził do zestawu kontrolnego graczy strojonych po nim. Funkcją celu był średni współczynnik wygranych wobec trzech przeciwników kontrolnych; budżet strojenia $B_{\text{tune}} = 2000$, 30 prób na algorytm, 60 partii na próbę. Heurystyki strojono raz (na Cooldown) i reużyto w obu wariantach; warianty MCTS strojono osobno na każdym wariancie gry. Końcowe wartości zebrano w tabeli 2.

Maszyna i czas. Eksperymenty uruchomiono na wynajętej maszynie CPU (128 rdzeni, 1 TiB RAM, Python 3.12); obliczenia zrównoleglono na poziomie partii (multiprocessing). Strojenie zajęło ok. 48 min, a turniej i samogra przy $B = 10\,000$ – kilkadziesiąt minut; pojedyncza partia dwóch graczy MCTS przy $B = 10\,000$ trwa ok. 70 s. GPU nie jest tu przydatne (przeszukiwanie drzewa jest sekwencyjne), więc skalujemy liczbą rdzeni.

Analiza statystyczna. Współczynniki wygranych raportujemy z 95% przedziałem ufności Wilsona [12]; istotność: test dwumianowy (pojedyncze pary) i test McNemara [11] (porównania sparowane po ziarnach), z korektą Holma–Bonferroniego [9] dla rodziny hipotez. Remisy (rzadkie) liczymy jako pół wygranej wyłącznie przy raportowaniu współczynnika wygranych; w testach istotności nie wnoszą pół-punktu.

Implementacja. Silnik gry i warianty MCTS napisano od zera w czystym Pythonie (bez zależności zewnętrznych); analizę i strojenie oparto o NumPy/SciPy/Pandas/Matplotlib oraz Optunę. Poprawność reguł potwierdzono testami jednostkowymi oraz testem różnicowym (zgodność generatora ruchów z niezależną implementacją na 4144 pozycjach). Każda partia jest odtwarzalna z ziaren; kod jest publiczny, a wyniki zapisywane przyrostowo (wznawialnie).

7 Wyniki

7.1 Ranking i współczynniki wygranych

Na podstawie 6000 partii turniejowych (po 3000 na wariant) tabela 1 i rysunek 4 podają średni współczynnik wygranych każdej metody, uśredniony po wszystkich jej partiach. W obu wariantach MCTS zdecydowanie przewyższa heurystyki. Najsilniejszy uśredniając oba warianty – i zarazem najbardziej stabilny – jest **UCT-PB-cooldown**, jako jedyny utrzymujący wysoki wynik w obu wariantach (0,84/0,81). Ciekawe są dwa zjawiska: UCT-PB-naïve jest mocny na klasyku (0,86), ale *załamuje się* pod regułą stygnięcia (0,64) – naiwna heurystyka myli poszukiwanie; bazowy UCT przeciwnie – wygląda na *lepszego* pod regułą (0,79) niż na klasyku (0,63), choć ten niski wynik na klasyku to w dużej mierze artefakt strojenia (źle dobrane c – por. sekcja 7.4).





Tabela 1: Ranking: średni współczynnik wygranych każdej metody, uśredniony po wszystkich jej partiach turniejowych.

Metoda	klasyk	cooldown
UCT-PB-cooldown	0,844	0,814
UCT-PB-naive	0,859	0,644
UCT	0,632	0,788
Cooldown-Buro	0,346	0,424
Naive-Buro	0,279	0,278
Random	0,040	0,052

Rysunek 4: Średni współczynnik wygranych metod na obu wariantach gry (te same dane co tab. 1).


Pełną strukturę par pokazują heatmapy współczynników wygranych (rys. 5): wartość to odsetek wygranych gracza z wiersza przeciw graczowi z kolumny.



Rysunek 5: Współczynnik wygranych gracza w wierszu przeciw graczowi w kolumnie. Etykiety wierszy wspólne dla obu map (pominięte po prawej).

7.2 Różnice pionków na końcu partii


Rysunek 6 pokazuje rozkłady różnicy pionków na końcu partii (z perspektywy danej metody). Silniejsze metody nie tylko wygrywają częściej, ale i wyraźniejszą przewagą pionków; heurystyki i gracz losowy mają mediany ujemne lub bliskie zera.



Rysunek 6: Różnica pionków na końcu partii (metoda – przeciwnik), wg metody i wariantu. Czerwone linie przerywane oznaczają maksymalną teoretyczną różnicę (± 36 na planszy 6×6).

7.3 Metryki specyficzne dla reguły stygnięcia


Aby zmierzyć, jak często reguła w ogóle „działa”, śledzimy, w jakiej części decyzji reguła blokuje ruch, który byłby legalny w klasyce (rys. 7). Mediana wynosi ok. **0,56** – reguła usuwa jakąś dostępną w klasyce opcję w ponad połowie decyzji, więc realnie ingeruje w grę. Patrząc z drugiej strony: w partiach klasycznych ok. **28%** faktycznie zagranych ruchów to natychmiastowe odbicia (*whipsaw*), które reguła stygnięcia eliminuje. Obie liczby mierzą *częstość aktywacji* reguły, a nie jakość konkretnego ruchu.



Rysunek 7: Rozkład *częstości aktywacji* reguły stygnięcia: w partiach Cooldown, na jaką część decyzji co najmniej jeden ruch legalny w klasyce jest blokowany przez regułę. Mediana wynosi ok. 0,56 – reguła usuwa jakąś opcję w ponad połowie decyzji, czyli realnie ingeruje w grę. (Metryka mierzy częstość, nie jakość zablokowanego ruchu.)


Bardziej bezpośrednim skutkiem reguły jest „długość życia” pionka – ile razy dane pole

zostaje odwrócone w partii (rys. 8). Pod regułą stygnięcia rozkład ma *krótszy ogon*: pionki są rzadziej wielokrotnie odbijane, bo świeże bicia są chwilowo chronione – co jest istotą modyfikacji.



Rysunek 8: Rozkład „długości życia” pionka – maksymalnej liczby odwróceń pojedynczego pola w partii. Pod regułą stygnięcia rozkład ma wyraźnie krótszy ogon – świeże bicia są chwilowo chronione.

Skutkiem ubocznym usuwania bić jest częstsze *zablokowanie strony* – sytuacja, w której gracz nie ma żadnego legalnego ruchu i musi spasować. Każda partia kończy się dwoma pasami (zapełniona plansza), więc miarodajne są pasy *w fazie środkowej* (rys. 9). Reguła stygnięcia podnosi odsetek partii z co najmniej jednym takim zablokowaniem z **57% do 70%** (turniej, 3000 partii na wariant), a średnią liczbę takich pasów z **1,07 do 1,57**. Efekt potwierdza się w self-play tym samym, najsilniejszym silnikiem (48% → 65%), więc wynika z reguły, a nie z doboru graczy; ogólny odsetek pasów na półruch rośnie z 8,8% do 10,1%. Jest to spójne z niższym współczynnikiem rozgałęzienia z sekcji 2.3 – mniej legalnych opcji częściej zamraża stronę.



Rysunek 9: Rozkład liczby wymuszonych pasów na partię (strona bez legalnego ruchu, poza końcowymi dwoma) w obu wariantach turnieju.


7.4 Strojenie hiperparametrów

Końcowe hiperparametry zebrano w tabeli 2. Najciekawsza obserwacja: stała eksploracji c dla UCT wypada po przeciwnych stronach zakresu dla obu wariantów (2,23 klasyk vs 0,52 cooldown). Rysunek 10 wyjaśnia dlaczego – zależność funkcji celu od c jest prawie płaska: silny UCT i tak pokonuje (słaby dla niego) zestaw kontrolny, więc współczynnik wygranych nasycy się i c jest słabo ograniczone (na Cooldown widać dodatkowo łagodną preferencję małego c). Dla wariantów z progressive bias zależność jest wyraźniejsza – niski

c idzie w parze z wysokim w_H (silne kierowanie heurystyką zastępuje eksplorację UCB), co najlepiej widać dla UCT-PB-cooldown na Cooldown ($c=0,54$, $w_H=8,7$).

Metoda	Wariant	c	w_{mob}	λ_c	w_H	WR (strojenie)
Naive-Buro	oba*	–	4,75	–	–	0,583
Cooldown-Buro	oba*	–	2,49	0,52	–	0,708
UCT	classic	2,23	–	–	–	0,958
UCT	cooldown	0,52	–	–	–	0,950
UCT-PB-naive	classic	0,75	–	–	2,42	0,933
UCT-PB-naive	cooldown	1,11	–	–	1,12	0,842
UCT-PB-cooldown	classic	0,72	–	–	5,02	0,817
UCT-PB-cooldown	cooldown	0,54	–	–	8,71	0,717

Tabela 2: Końcowe hiperparametry po strojeniu (Optuna TPE) oraz współczynnik wygranych wobec zestawu kontrolnego. *heurystyki strojono raz na Cooldown i reużyto w obu wariantach gry.




Rysunek 10: Zależność celu strojenia od stałej eksploracji c (PDP/slice; każdy punkt to jedna próba Optuny). Czerwona linia przerywana – najlepsze c , czarna kropkowana – $\sqrt{2}$ (literatura). Funkcja jest niemal płaska, więc c jest słabo ograniczone.

Jak bardzo strojenie wpłynęło na wyniki? Płaska funkcja celu (rys. 10) ostrzega, że strojenie silnych graczy jest słabo ograniczone – ale czy faktycznie nie zaszkodziło? Aby to sprawdzić, powtórzyliśmy *cały* turniej z parametrami domyślnymi (literaturowymi: $c=\sqrt{2}$, wagi=1,0) na tych samych parach i ziarnach, po czym porównaliśmy oba rankingi (tab. 3, rys. 11). Efekt okazał się *niejednorodny*: średnia bezwzględna zmiana współczynnika wygranych to ok. 6 p.p., a w skrajnym przypadku aż 16 p.p. Strojenie pomogło heurystyce Cooldown-Buro oraz wariantowi progressive bias świadomemu reguły, ale *zaszkodziło* kilku graczom – najmocniej bazowemu UCT na klasyku, gdzie wybrane $c=2,23$ daje wynik o 16 p.p. *gorszy* niż literaturowe $\sqrt{2}$. To bezpośredni skutek nasycenia: cel strojenia (wobec słabych zestawów kontrolnych) nie odróżniał dobrych wartości c od złych, więc wybór nie uogólnił się na pełną stawkę. Ranking jest odporny na krańcach (UCT-PB-cooldown na czele, Random na końcu), ale środek się przetasowuje – przy parametrach domyślnych trzy warianty MCTS są niemal równe. Wniosek: nasza kaskada strojenia była

dla najsilniejszych graczy *co najwyżej neutralna*, a lokalnie szkodliwa; przewaga tych graczy pochodzi z samego MCTS, nie z kalibracji parametrów. Naturalny kierunek poprawy to silniejsze zestawy kontrolne w strojeniu.

Metoda	klasyk: str.	dom.	Δ	cooldown: str.	dom.	Δ
UCT-PB-cooldown	0,844	0,787	+6	0,814	0,741	+7
UCT-PB-naive	0,859	0,805	+5	0,644	0,749	-10
UCT	0,632	0,797	-16	0,788	0,737	+5
Cooldown-Buro	0,346	0,303	+4	0,424	0,332	+9
Naive-Buro	0,279	0,280	0	0,278	0,382	-10
Random	0,040	0,028	+1	0,052	0,059	-1

Tabela 3: Wpływ strojenia na wyniki końcowe: średni współczynnik wygranych każdej metody z parametrami *strojonymi* (str.) i *domyślnymi* literaturowymi (dom.: $c=\sqrt{2}$, wagi=1,0), wraz z różnicą Δ w punktach procentowych. Te same pary i ziarna w obu turniejach.



Rysunek 11: Wpływ strojenia na wyniki końcowe: średni współczynnik wygranych każdej metody z parametrami *strojonymi* vs *domyślnymi* literaturowymi ($c=\sqrt{2}$, wagi=1,0). Efekt jest niejednorodny (śr. $|\Delta| \approx 6$ p.p.); najsilniej widać go dla bazowego UCT na klasyku, gdzie strojenie *zaszkodziło*. Ranking jest stabilny na krańcach, środek się przetasowuje.

8 Weryfikacja hipotez

Hipoteza	Wynik	kluczowy efekt	p	holm- p
H1	potwierdzona	WR 0,88/0,77 (cd/kl)	<0,001	<0,001
H2	odrzucona	+4 p.p. nad UCT	0,289	0,289
H3	odrzucona	+50/+26 p.p. (cd/kl)	<0,001	<0,001
H4	potwierdzona	biały 0,58/0,49 (kl/cd)	<0,001	<0,001

Tabela 4: Weryfikacja hipotez (wielkość efektu, p -wartość testu i p po korekcie Holma–Bonferroniego).

H1 – potwierdzona. UCT pokonuje Naive-Buro w 88% partii na Cooldown (95% CI: 0,82–0,92; $\geq 60\%$) i w 77% na klasyku; przewaga jest o ok. 11 p.p. większa pod regułą stygnięcia ($p \approx 10^{-29}$). Zgodnie z intuicją: reguła komplikuje ocenę pozycyjną, a MCTS lepiej radzi sobie z zależnością od historii.

H2 – odrzucona. UCT-PB-cooldown pokonuje bazowy UCT na Cooldown jedynie o ok. 4 p.p. (próg 10 p.p. nieosiągnięty, różnica nieistotna), a UCT-PB-naive wręcz *przegrywa* z bazowym UCT. Progressive bias pomaga więc tylko z heurystyką świadomą reguły i to nieznacznie, a z naiwną szkodzi.

H3 – odrzucona. Na Cooldown Cooldown-Buro pokonuje Naive-Buro w 100% (przewaga $\gg 10$ p.p.), ale na klasyku również wygrywa (o ok. 26 p.p.), zamiast być równoważna. Heurystyka świadoma reguły jest po prostu lepsza w obu wariantach – jej człon „trwałości bicia” jest użyteczny także w klasycznym Othello – więc nie udało się wyizolować efektu samej reguły.

H4 – potwierdzona. W samogrze (po 2000 partii na wariant) drugi gracz wygrywa 58,4% partii na klasyku (95% CI: 0,562–0,605; istotnie $> 50\%$), ale tylko 49,1% pod regułą stygnięcia (95% CI: 0,469–0,513; nieodróżnialne od 50%). W samogrze badanego agenta wyraźna w klasyku przewaga drugiego gracza *zanika* pod regułą (wynik empiryczny dla tego ustawienia, a nie twierdzenie teoriogrowe) – whipsaw jest taktyką reaktywną, więc jego eliminacja odbiera przewagę graczowi odpowiadającemu.


9 Eksperyment człowiek–komputer

Przeprowadziliśmy wstępny, nieformalny test z udziałem trojga graczy o różnym poziomie zaawansowania, w działającym interfejsie webowym gry. Każdy rozegrał po cztery partie przeciw trzem przeciwnikom dostępnym w aplikacji – losowemu (Random), heurystyce Cooldown-Buro oraz najsilniejszemu agentowi UCT-PB-cooldown ($B = 10\,000$) – wyłączając w wariancie z regułą stygnięcia. Ze względu na małą próbę (troje grających, po cztery partie na przeciwnika) traktujemy wyniki *jakościowo* – jako test użyteczności interfejsu i ilustrację poziomów trudności, a nie estymację siły agentów wobec ludzi.

Zbiórce wyniki przedstawia tabela 5; wyłania się z nich wyraźna drabina poziomów. Wszyscy gracze regularnie wygrywali z przeciwnikiem losowym, ale już heurystyka Cooldown-Buro rozdzieliła ich umiejętności, a najsilniejszego agenta UCT-PB-cooldown nie pokonał *nikt* (rys. 12) – co jest spójne z jego dominacją w turnieju (sekcja 7).

Gracz	Random	Cooldown-Buro	UCT-PB-cooldown	mediana czasu/ruch
Osoba 1	3-1 (+0,5)	1-3 (-12,0)	0-4 (-12,8)	4,7 s
Osoba 2	4-0 (+14,0)	3-1 (+5,2)	0-4 (-5,8)	12,5 s
Osoba 3	2-2 (-2,0)	0-4 (-16,0)	0-4 (-25,0)	2,0 s

Tabela 5: Mini-test człowiek–komputer w wariancie stygnięcia: po cztery partie każdego gracza przeciw trzem przeciwnikom obecnym w aplikacji. W komórkach rekord *wygrane–przegrane* oraz (w nawiasie) średnia różnica pionków z perspektywy człowieka. Ostatnia kolumna – mediana czasu namysłu na ruch. Żaden z graczy nie pokonał najsilniejszego agenta UCT-PB-cooldown.



Rysunek 12: Odsetek partii wygranych przez każdego z trzech graczy-ludzi przeciw trzem przeciwnikom (wariant stygnięcia, po cztery partie na parę). Z Random wygrywa każdy, z heurystyką Cooldown-Buro ujawnia się różnica umiejętności, a najsilniejszego agenta UCT-PB-cooldown nie pokonał nikt.

Najważniejsza obserwacja jakościowa: **gra jest naprawdę trudna dla kogoś, kto nie zetknął się z nią wcześniej**. Nawet pokonanie prostej heurystyki wymaga kilku partii wprawy, a reguła stygnięcia *dodatkowo* podnosi złożoność – trzeba wybiegać myślą poza bieżące bicie i pamiętać, które pionki są chwilowo chronione (sekcja 2.2). Pokrywa się to z analizą złożoności z sekcji 2.3: usuwanie natychmiastowych odbić czyni pozycje mniej intuicyjnymi i wyraźnie podnosi próg wejścia dla człowieka.

10 Podsumowanie i wnioski

Spośród czterech hipotez potwierdziły się dwie (H1, H4), a dwie odrzuciliśmy (H2, H3); odrzucenia są pouczające, nie negatywne. Najważniejsze wnioski:

- **Zysk pochodzi z MCTS, nie z progressive bias.** UCT-PB-cooldown jest najsilniejszy, ale jego przewaga nad bazowym UCT jest niewielka; dodatkowo naiwna heurystyka w progressive bias *szkodzi* pod regułą (UCT-PB-naive: 0,86 klasyk $\rightarrow$ 0,64 cooldown).
- **Świadomość reguły ma znaczenie dla heurystyki.** Cooldown-Buro miażdży Naive-Buro pod regułą (100%). Reguła nie „karze” ruchów – nielegalne bicie są po prostu niedostępne – lecz naiwna ocena wybiera legalne bicie, które reguła czyni kruchymi (stąd zapasć Naive-Buro).

- **Heurystyka „trwałości bicia” jest ogólnie wartościowa** – pomaga także w klasyku, a nie tylko pod regułą (stąd odrzucenie H3 jako hipotezy o izolacji efektu).
- **Reguła zmienia balans gry** – znika strukturalna przewaga drugiego gracza (H4), więc Cooldown Othello jest wariantem bardziej zrównoważonym, a jednocześnie realnie ingeruje w grę (krótszy ogon „długości życia” pionków, blokada jakiejś opcji w ponad połowie decyzji oraz częstsze zablokowanie strony bez ruchu: 57% → 70% partii, rys. 9).
- **Strojenie kaskadowe nie poprawiło silnych graczy.** Powtórzenie turnieju z parametrami domyślnymi zmienia wyniki średnio o ok. 6 p.p. w niejednorodnych kierunkach, a bazowemu UCT na klasyku strojenie wręcz *zaszkodziło* (źle dobrane c). Przewaga najlepszych graczy pochodzi z MCTS, nie z kalibracji hiperparametrów – a cel strojenia warto wzmocnić silniejszymi zestawami kontrolnymi (sekcja 7.4).
- **Ostrożnie z porównaniem klasyk-cooldown dla samego UCT.** Pozorna przewaga bazowego UCT pod regułą (0,79 vs 0,63) wynika w dużej mierze ze źle dobranego c na klasyku; przy parametrach domyślnych ta różnica niemal znika.

Ograniczenia i dalsze prace. Wyniki warto czytać z kilkoma zastrzeżeniami. Po pierwsze, strojenie hiperparametrów mogło wpłynąć na rozstrzygnięcie części hipotez – w szczególności H3: Cooldown-Buro strojono na zestawie kontrolnym obejmującym m.in. Naive-Buro, więc jego przewagę nad Naive-Buro należy traktować jako potwierdzenie skuteczności *strojonej* heurystyki, a nie dowód wyższości samej konstrukcji ręcznej. Po drugie, dla najsilniejszych graczy funkcja celu strojenia była nasycona (sekcja 7.4), więc dobór parametrów jest słabo ograniczony. Po trzecie, test człowiek–komputer jest mały i nieformalny. Naturalne kierunki dalszych prac to silniejsze zestawy kontrolne w strojeniu wraz z niezależnym sprawdzeniem H3 na parametrach domyślnych, przedziały ufności w tabeli rankingowej oraz właściwe badanie z udziałem ludzi.

11 Wykorzystanie dużych modeli językowych

Projekt zrealizowano z użyciem asystenta opartego o duży model językowy (Claude, Anthropic) w roli pary programistycznej: implementacja silnika gry i wariantów MCTS, skryptów strojenia i analizy, orkiestracja eksperymentów na maszynie zdalnej oraz redakcja raportu. Wszystkie decyzje projektowe, weryfikacja poprawności (testy jednostkowe i różnicowe) oraz interpretacja wyników były nadzorowane przez autora.

Literatura

- [1] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2623–2631. ACM, 2019.
- [2] Peter Auer, Nicolò Cesa-Bianchi, and Paul Fischer. Finite-time analysis of the multiarmed bandit problem. *Machine Learning*, 47(2–3):235–256, 2002.
- [3] Cameron B. Browne, Edward Powley, Daniel Whitehouse, Simon M. Lucas, Peter I. Cowling, Philipp Rohlfshagen, Stephen Tavenor, Diego Perez, Spyridon Samothrakis,

- and Simon Colton. A survey of Monte Carlo tree search methods. *IEEE Transactions on Computational Intelligence and AI in Games*, 4(1):1–43, 2012.
- [4] Michael Buro. An evaluation function for Othello based on statistics. Technical Report 31, NEC Research Institute, 1997.
 - [5] Michael Buro. The evolution of strong Othello programs. In *Entertainment Computing: Technologies and Applications*, pages 81–88. Springer, 2003.
 - [6] Guillaume M. J.-B. Chaslot, Mark H. M. Winands, H. Jaap van den Herik, Jos W. H. M. Uiterwijk, and Bruno Bouzy. Progressive strategies for Monte-Carlo tree search. *New Mathematics and Natural Computation*, 4(3):343–357, 2008.
 - [7] Benjamin E. Childs, James H. Brodeur, and Levente Kocsis. Transpositions and move groups in Monte Carlo tree search. In *2008 IEEE Symposium on Computational Intelligence and Games*, pages 389–395. IEEE, 2008.
 - [8] Rémi Coulom. Efficient selectivity and backup operators in Monte-Carlo tree search. In *Computers and Games (CG 2006)*, volume 4630 of *Lecture Notes in Computer Science*, pages 72–83. Springer, 2007.
 - [9] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979.
 - [10] Levente Kocsis and Csaba Szepesvári. Bandit based Monte-Carlo planning. In *Machine Learning: ECML 2006*, volume 4212 of *Lecture Notes in Computer Science*, pages 282–293. Springer, 2006.
 - [11] Quinn McNemar. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157, 1947.
 - [12] Edwin B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212, 1927.