



Politechnika Warszawska

**Wydział Matematyki
i Nauk Informatycznych**

Metody Sztucznej Inteligencji 2

MCTS/UCT w grze Cooldown Othello 6×6

Autor:

Wojciech Jasiński

Prowadzący:

mgr inż. Bartłomiej Olechno

Warszawa, czerwiec 2026

Streszczenie

Badamy sztuczną inteligencję do gry planszowej opartą o Monte Carlo Tree Search (MCTS) i jego wariant UCT. Jako grę wybraliśmy Othello na planszy 6×6 z autorską *regułą stygnięcia*: pionki postawione lub odwrócone w poprzedniej turze są chwilowo chronione, co eliminuje natychmiastowe odbijanie (*whipsaw*) i wprowadza do gry zależność od historii. Porównujemy sześciu graczy: losowego, dwie heurystyki pozycyjne Buro (klasyczną i świadomą reguły stygnięcia), bazowy UCT oraz UCT z ulepszeniem *progressive bias* (z obiema heurystykami) – na klasycznym Othello 6×6 i na wariancie z regułą stygnięcia.

Przeprowadziliśmy turniej round-robin (6000 partii przy budżecie 10 000 symulacji na ruch) oraz samogrę najsilniejszego gracza, z hiperparametrami strojonymi metodą Optuna TPE. Najważniejsze wyniki: (H1) UCT wyraźnie pokonuje heurystyki, a jego przewaga jest większa pod regułą stygnięcia (88% vs 77% wygranych z Naive-Buro); (H2) progressive bias daje tylko niewielki zysk i tylko z heurystyką świadomą reguły – z naiwną heurystyką wręcz szkodzi; (H3) heurystyka świadoma reguły jest lepsza w *obu* wariantach gry, a nie tylko pod regułą stygnięcia, więc nie udało się wyizolować efektu samej reguły. Potwierdziła się natomiast H4: strukturalna przewaga drugiego gracza (58% wygranych w klasyku) zanika pod regułą stygnięcia (49%, nieodróżnialne od 50%).

Spis treści

1	Wprowadzenie	1
2	Gra i reguła stygnięcia	1
3	Algorytmy	1
4	Hipotezy badawcze	2
5	Metodologia	2
6	Wyniki	2
6.1	Turniej – współczynniki wygranych	2
6.2	Różnice pionków i metryki reguły	3
6.3	Strojenie hiperparametrów	3
7	Weryfikacja hipotez	4
8	Podsumowanie i wnioski	5
9	Wykorzystanie dużych modeli językowych	5

1 Wprowadzenie

Celem projektu jest zaprojektowanie i empiryczna analiza AI do dwuosobowej gry z pełną informacją, opartej o MCTS/UCT [7, 3, 8]. Porównujemy wariant bazowy z ulepszeniem *progressive bias* [5], w którym wybór ruchu jest dodatkowo kierowany heurystyką dziedzinową. Jako grę wybraliśmy Othello – klasyczną grę o prostych zasadach i bogatej literaturze heurystyk pozycyjnych [4] – na zmniejszonej planszy 6×6 , do której wprowadzamy autorską *regułę stygnięcia*. Reguła ta zmienia wartość ruchów względem klasyki i pozwala zadać pytanie: czy klasyczne heurystyki i MCTS radzą sobie w zmienionych warunkach.

2 Gra i reguła stygnięcia

Othello. Deterministyczna gra dwuosobowa na planszy, czarny rusza pierwszy. Ruch polega na postawieniu pionka tak, by w co najmniej jednym kierunku domknąć linię pionków przeciwnika zakończoną własnym pionkiem; domknięte pionki są odwracane na własny kolor. Brak legalnego ruchu oznacza pas; dwa pasy pod rząd kończą grę. Wygrywa gracz z większą liczbą pionków. Gramy na planszy 6×6 (zamiast 8×8), co redukuje przestrzeń stanów do skali umożliwiającej wiarygodne porównania wielu wariantów MCTS.

Reguła stygnięcia (Cooldown). Stan gry to para (B, C) : plansza B oraz zbiór C pól ze znacznikiem stygnięcia (pionki postawione lub odwrócone w poprzedniej turze). Pionek ze znacznikiem jest *przezroczysty* – nie kończy linii domykania i nie może zostać odwrócony w tej turze. Linia jest legalna tylko, jeśli zawiera co najmniej jeden pionek przeciwnika *bez* znacznika. Po ruchu: stare znaczniki znikają, odwracamy tylko pionki bez znacznika, a nowy zbiór C to pole postawione plus wszystkie pionki właśnie odwrócone. Pas zeruje C .

Reguła eliminuje *whipsaw* (naprzemienne odbijanie tych samych pionków) i wprowadza zależność od historii: dwie identyczne plansze osiągnięte różnymi ścieżkami nie są tożsame, co osłabia klasyczne tablice transpozycji [6] oraz wagi pozycyjne kalibrowane dla swobodnego bicia.

Weryfikacja złożoności. W 1000 partiach losowych zmierzaliśmy średnią długość gry i rozgałęzienie. Reguła stygnięcia obniża średnie rozgałęzienie (z 5,3 do 4,5), ale nie skraca gry (ok. 34 pólruchów w obu wariantach) – plansza i tak się zwypełnia. Wstępne szacunki z konspektu (długość 28) okazały się zaniżone; rozgałęzienie (~ 4 – 5) zgadza się z oczekiwaniem.

3 Algorytmy

MCTS/UCT. Pojedyncza iteracja MCTS to selekcja, ekspansja, symulacja (losowe rozegranie do końca) i backpropagacja. UCT [8] w selekcji wybiera ruch maksymalizujący górną granicę ufności UCB1 [2]:

$$\text{UCB1}(s, a) = \overline{Q}(s, a) + c \sqrt{\frac{\ln N(s)}{N(s, a)}},$$

gdzie c to stała eksploracji, a budżet B to liczba iteracji na ruch. W naszej implementacji węzeł przechowuje pełny stan (B, C) – ze względu na zależność od historii nie używamy tablic transpozycji.

Progressive bias. Do UCB1 dodajemy człon $w_H H(s, a)/(N(s, a) + 1)$, gdzie H to heurystyka dziedzinowa [5]. Przy małej liczbie odwiedzin heurystyka silnie kieruje wyborem, później jej wpływ maleje.

Heurystyki Buro. Klasyczna heurystyka [4] łączy wagi pozycyjne (rogi cenne, pola przy rogach deficytowe) z różnicą mobilności (wagą w_{mob}). *Cooldown-Buro* rozszerza ją o człon (waga λ_c) nagradzający bicia trwale i karzący bicia, które przeciwnik łatwo odwróci po wygaśnięciu stygnięcia.

4 Hipotezy badawcze

- H1** UCT pokonuje Naive-Buro w obu wariantach ($\geq 60\%$ na Cooldown), a jego przewaga jest istotnie większa na Cooldown niż na klasyku.
- H2** UCT+progressive-bias z Cooldown-Buro pokonuje bazowy UCT na Cooldown o ≥ 10 p.p., wyraźniej niż wariant z naiwną heurystyką.
- H3** Cooldown-Buro pokonuje Naive-Buro na Cooldown (≥ 10 p.p.), ale na klasyku obie są praktycznie równoważne (< 5 p.p.).
- H4** Strukturalna przewaga drugiego gracza w klasycznym 6×6 zanika pod regułą stygnięcia (samogra najsilniejszego wariantu).

5 Metodologia

Gracze. Random; Naive-Buro i Cooldown-Buro (jednowarstwowy negamax); UCT; UCT-PB-naive i UCT-PB-cooldown (progressive bias z odpowiednią heurystyką).

Konfiguracja. Budżet $B = 10\,000$ symulacji na ruch dla MCTS; turniej round-robin (15 par) po 200 partii na parę z zamianą kolorów, dla obu wariantów gry (~ 6000 partii). Samogra najsilniejszego wariantu (≥ 2000 partii na wariant) do weryfikacji H4. Każda partia jest odtwarzalna z ziaren (gra, czarny, biały).

Strojenie hiperparametrów. Optuna z samplerem TPE [1], kaskadowo: każdy ustrojony gracz wchodzi do zestawu kontrolnego kolejnych. Funkcją celu jest średni współczynnik wygranych z trzema kontrolnymi przeciwnikami; budżet strojenia $B_{\text{tune}} = 2000$, 30 prób na algorytm, 60 partii na próbę. Heurystyki strojono raz (na Cooldown), warianty MCTS osobno na każdym wariancie gry.


Analiza statystyczna. Współczynnik wygranych z 95% przedziałem ufności Wilsona; test dwumianowy; test McNemara dla porównań sparowanych po ziarnach; korekta Holma–Bonferroniego. Implementacja w Pythonie (silnik gry i MCTS od zera; NumPy/SciPy/Pandas/Matplotlib/Optuna), kod publiczny, eksperymenty zrównoleglone (multiprocessing).

6 Wyniki

6.1 Turniej – współczynniki wygranych

Rysunek 1 pokazuje współczynniki wygranych każdej pary graczy. W obu wariantach MCTS zdecydowanie przewyższa heurystyki. Wśród wariantów MCTS najsilniejszy jest

UCT-PB-cooldown, tuż przed bazowym UCT; UCT-PB-naive wypada najsłabiej z rodziny MCTS (przegrywa nawet z bazowym UCT).




(a) Klasyczne 6×6

(b) Cooldown 6×6

Rysunek 1: Współczynnik wygranych gracza w wierszu przeciw graczowi w kolumnie.

6.2 Różnice pionków i metryki reguły

Rysunek 2 (lewy) pokazuje rozkłady różnicy pionków na końcu partii, a (prawy) metryki specyficzne dla reguły: *whipsaw rate* (jak często w klasyku padłby ruch nielegalny pod regułą) oraz *cooldown-blocked rate* (jak często reguła blokuje atrakcyjny ruch).




(a) Różnica pionków (focal — przeciwnik)

(b) Metryki reguły stygnięcia

Rysunek 2: Rozkłady wyników i metryki specyficzne dla reguły.

6.3 Strojenie hiperparametrów

Rysunek 3 pokazuje zależność funkcji celu od stałej eksploracji c dla UCT. Na klasyku funkcja jest niemal płaska (UCT przytłacza zestaw kontrolny, więc c jest słabo ograniczone), na Cooldown widać łagodną preferencję małego c . To wyjaśnia, dlaczego strojone c wypada po przeciwnych stronach zakresu dla obu wariantów.



Rysunek 3: Zależność współczynnika wygranych UCT od stałej eksploracji c (PDP/slice).

7 Weryfikacja hipotez

Hip.	Wynik	kluczowy efekt	p	holm- p
H1	tak	WR cooldown 0.88	0.000	0.000
H2	nie	przewaga 4 p.p.	0.289	0.289
H3	nie	cool 50 / klasyk 26 p.p.	0.000	0.000
H4	tak	biały 0.58 / 0.49	0.000	0.000

Tabela 1: Weryfikacja hipotez (wielkość efektu + p).

H1 – potwierdzona. UCT pokonuje Naive-Buro w 88% na Cooldown (95% CI: 0,82–0,92; $\geq 60\%$) i w 77% na klasyku; przewaga jest o ok. 11 p.p. większa pod regułą stygnięcia ($p \approx 10^{-29}$). Zgodnie z intuicją – reguła komplikuje ocenę pozycyjną, a MCTS lepiej radzi sobie z zależnością od historii.

H2 – odrzucona. UCT-PB-cooldown pokonuje bazowy UCT na Cooldown jedynie o ok. 4 p.p. (próg 10 p.p. nieosiągnięty, różnica nieistotna). Co więcej, UCT-PB-naive *przegrywa* z bazowym UCT. Wniosek: progressive bias pomaga tylko z heurystyką świadomą reguły i to nieznacznie, a z heurystyką naiwną szkodzi.

H3 – odrzucona. Na Cooldown Cooldown-Buro pokonuje Naive-Buro w 100% (przewaga $\gg 10$ p.p.), ale na klasyku również wygrywa (o ok. 26 p.p.), zamiast być równoważna. Heurystyka świadoma reguły jest więc po prostu lepsza w obu wariantach – jej człon „trwałości bicia” jest użyteczny także w klasycznym Othello – więc nie udało się wyizolować efektu samej reguły.

H4 – potwierdzona. W samogrze najsilniejszego wariantu (po 2000 partii na wariant) drugi gracz (biały) wygrywa 58,4% partii na klasycznym 6×6 (95% CI: 0,562–0,605; istotnie $> 50\%$), ale tylko 49,1% pod regułą stygnięcia (95% CI: 0,469–0,513; nieodróżnialne od 50%). Strukturalna przewaga drugiego gracza istnieje więc w klasyku i *zanika* pod

regułą stygnięcia – zgodnie z intuicją, że eliminacja whipsaw odbiera graczowi odpowiadającemu reaktywną przewagę.

8 Podsumowanie i wnioski

Spośród czterech hipotez potwierdziły się dwie (H1, H4), a dwie odrzuciliśmy (H2, H3) – przy czym odrzucenia są pouczające, nie negatywne. Najsilniejszym graczem okazał się UCT-PB-cooldown, choć jego przewaga nad bazowym UCT jest niewielka – główny zysk pochodzi z samego MCTS, nie z progressive bias. Reguła stygnięcia realnie zmienia grę (obniża rozgałęzienie, karze „naiwne” bicia), co najmocniej widać w zapaści Naive-Buro na Cooldown. Zaskakującym wynikiem jest to, że heurystyka świadoma reguły pomaga także w klasycznym Othello – sugeruje to, że „trwałość bicia” jest ogólnie wartościowym sygnałem, a nie tylko sztuczką pod jedną regułą. Reguła zmienia też balans gry: znika strukturalna przewaga drugiego gracza, co czyni Cooldown Othello bardziej zrównoważonym wariantem.

Ograniczeniem badania jest słaba czułość funkcji celu strojenia dla silnych graczy (płaska zależność od c), przez co część hiperparametrów MCTS jest słabo ograniczona; w dalszych pracach warto wzmocnić zestawy kontrolne. Eksperyment człowiek–komputer pozostawiamy jako naturalne rozszerzenie (gotowy interfejs webowy).

9 Wykorzystanie dużych modeli językowych

Projekt zrealizowano z użyciem asystenta opartego o duży model językowy (Claude, Anthropic) w roli pary programistycznej: implementacja silnika gry i wariantów MCTS, skryptów strojenia i analizy, orkiestracja eksperymentów na maszynie zdalnej oraz redakcja niniejszego raportu. Wszystkie decyzje projektowe, weryfikacja poprawności (testy jednostkowe i różnicowe) oraz interpretacja wyników były nadzorowane przez autora.

Literatura

- [1] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2623–2631. ACM, 2019.
- [2] Peter Auer, Nicolò Cesa-Bianchi, and Paul Fischer. Finite-time analysis of the multiarmed bandit problem. *Machine Learning*, 47(2–3):235–256, 2002.
- [3] Cameron B. Browne, Edward Powley, Daniel Whitehouse, Simon M. Lucas, Peter I. Cowling, Philipp Rohlfshagen, Stephen Tavener, Diego Perez, Spyridon Samothrakis, and Simon Colton. A survey of Monte Carlo tree search methods. *IEEE Transactions on Computational Intelligence and AI in Games*, 4(1):1–43, 2012.
- [4] Michael Buro. An evaluation function for Othello based on statistics. Technical Report 31, NEC Research Institute, 1997.

- [5] Guillaume M. J.-B. Chaslot, Mark H. M. Winands, H. Jaap van den Herik, Jos W. H. M. Uiterwijk, and Bruno Bouzy. Progressive strategies for Monte-Carlo tree search. *New Mathematics and Natural Computation*, 4(3):343–357, 2008.
- [6] Benjamin E. Childs, James H. Brodeur, and Levente Kocsis. Transpositions and move groups in Monte Carlo tree search. In *2008 IEEE Symposium on Computational Intelligence and Games*, pages 389–395. IEEE, 2008.
- [7] Rémi Coulom. Efficient selectivity and backup operators in Monte-Carlo tree search. In *Computers and Games (CG 2006)*, volume 4630 of *Lecture Notes in Computer Science*, pages 72–83. Springer, 2007.
- [8] Levente Kocsis and Csaba Szepesvári. Bandit based Monte-Carlo planning. In *Machine Learning: ECML 2006*, volume 4212 of *Lecture Notes in Computer Science*, pages 282–293. Springer, 2006.